PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS

NÚCLEO DE EDUCAÇÃO A DISTÂNCIA

Pós-graduação *Lato Sensu* em Analytics e Business Intelligence

RELATÓRIO TÉCNICO

O CRÉDITO PRONAF NO RIO GRANDE DO SUL: PERFIL DE CONTRATAÇÃO, CONCENTRAÇÃO MUNICIPAL E EFEITO DE EVENTOS CLIMÁTICOS SOBRE A DEMANDA POR CUSTEIO

Nadine Schneider

Belo Horizonte

2026

SUMÁRIO

1. Introdução..... 4
1.1. Contexto..... 4
1.2. Objetivos..... 5
1.3. Público alvo..... 6
2. Modelo de Dados..... 7
2.1. Modelo Dimensional..... 7
2.2. Fatos e Dimensões..... 8
3. Integração, Tratamento e Carga de Dados..... 11
3.1. Fontes de Dados..... 11
3.2. Processos de Integração e Carga (ETL)..... 13
4. Camada de Apresentação..... 17
4.1 Dashboard..... 17
4.2 Análises avançadas..... 26
5. Registros de Homologação..... 33
6. Conclusões..... 37
6.1. Análise crítica dos achados..... 37
6.2. Proposta de intervenção..... 39
6.3. Lições aprendidas..... 41
6.4. Limitações e possibilidades de extensão..... 43
7. Links..... 44
REFERÊNCIAS..... 45

1. Introdução

1.1. Contexto

Este projeto foi desenvolvido no contexto de uma agtech com atuação no Rio Grande do Sul, que atende produtores rurais de diferentes segmentos e portes por meio da comercialização de sensores de umidade do solo e de soluções digitais para a gestão da propriedade. A empresa conta com uma equipe comercial organizada regionalmente e, a cada ciclo do Plano Safra, precisa definir como distribuir seus representantes, quais culturas priorizar, em quais períodos intensificar as atividades em campo e com quais instituições financeiras estabelecer parcerias para a originação de crédito rural.

A principal motivação deste trabalho é a dificuldade de obter uma visão integrada da demanda por crédito rural na agricultura gaúcha. Atualmente, as decisões comerciais são orientadas principalmente pela experiência da equipe em campo, por relatórios setoriais com dados agregados e por planilhas elaboradas de forma independente. Embora as informações necessárias sejam públicas, elas não estão prontamente disponíveis para análise. O Sistema de Operações do Crédito Rural e do Proagro (SICOR), mantido pelo Banco Central do Brasil, disponibiliza registros individuais dos contratos de crédito rural, mas o seu volume, a distribuição em arquivos anuais de grande porte e a necessidade de relacionar diferentes tabelas de códigos e classificações dificultam o acesso e a utilização dos dados por profissionais sem conhecimento técnico especializado.

Outro aspecto relevante para o projeto é a exposição do Rio Grande do Sul a eventos climáticos extremos. As safras de 2021/2022 e 2022/2023 foram marcadas por estiagens severas, enquanto a safra de 2023/2024 foi fortemente impactada pelas enchentes que atingiram o estado. Ocorrências dessa natureza podem comprometer a produção, alterar as necessidades financeiras dos produtores e influenciar a procura por crédito de custeio. Apesar dessa relação potencial, a empresa ainda não havia realizado uma análise sistemática que permitisse observar como esses eventos se relacionam com o comportamento de contratação de crédito rural. Para essa investigação, o Atlas Digital de Desastres no Brasil representa uma fonte complementar de informação, pois reúne registros de reconhecimentos

federais de situações de emergência e de estados de calamidade pública, identificados por município e data.

O contexto técnico é o de uma empresa sem área de dados estruturada, não há ferramenta de ETL licenciada e o consumo de informação se dá por planilhas e apresentações. Portanto, qualquer solução proposta precisa ser reproduzível com ferramentas de custo baixo ou nulo e operável por uma pessoa.

1.2. Objetivos

O projeto tem como objetivo contribuir para uma alocação mais eficiente do esforço comercial da organização no Rio Grande do Sul, utilizando dados para fundamentar decisões que hoje dependem, em grande parte, da percepção da equipe e da experiência de campo. A proposta é identificar onde, quando e em quais culturas e por meio de quais instituições financeiras a agricultura familiar contrata crédito. A partir desse propósito, foram definidos quatro objetivos de negócio:

- Dimensionar o mercado potencial por município e região, fornecendo subsídios para decidir entre concentrar a atuação comercial nos principais polos de demanda ou ampliar a cobertura territorial.
- Alinhar o planejamento comercial ao calendário de contratação de crédito rural, permitindo direcionar as ações de campo para os períodos de maior movimentação.
- Apoiar a seleção de parceiros financeiros com base na participação de cada instituição na concessão de crédito do Programa Nacional de Fortalecimento da Agricultura Familiar (Pronaf) no estado.
- Compreender a relação entre a demanda por crédito de custeio e a ocorrência de eventos climáticos extremos, especialmente estiagens e enchentes, buscando identificar padrões que possam auxiliar no planejamento das safras seguintes.

Para alcançar esses resultados, o projeto também contempla objetivos específicos relacionados à construção da solução analítica. O primeiro consiste em desenvolver um data warehouse dimensional, seguindo a abordagem de Kimball, que integre os dados de crédito rural e de eventos climáticos por meio de dimensões conformadas. O segundo é automatizar os processos de extração, transformação e carga dos dados, incluindo o agendamento das execuções. O terceiro envolve desenvolver um painel analítico que reúna visões estratégicas, táticas e

operacionais, permitindo explorar as informações de forma integrada por meio de filtros.

Além disso, pretende-se aplicar uma técnica de aprendizado de máquina não supervisionado para agrupar os municípios gaúchos conforme suas características de contratação de crédito e exposição a eventos climáticos. A avaliação deverá considerar dados de teste que não tenham sido utilizados durante o treinamento do modelo. Por fim, será realizada a validação dos indicadores apresentados no painel, comparando os resultados exibidos com os dados efetivamente carregados no ambiente analítico.

1.3. Público alvo

A solução foi desenhada para a equipe da própria startup, um grupo pequeno em que as funções são compartilhadas, as mesmas pessoas planejam a estratégia comercial, visitam produtores, preparam propostas e mantêm o contato com cooperativas e bancos.

Os usuários conhecem bem o agronegócio e o crédito rural, mas têm familiaridade apenas intermediária com ferramentas analíticas. Usam planilhas, não dominam linguagem de consulta a bancos de dados e não têm a análise de dados como atribuição principal. Por isso, as três visões do painel não correspondem a públicos distintos, e sim a momentos de uso da mesma equipe. A estratégica serve ao planejamento do ciclo, as táticas à preparação do trabalho de campo e a operacional à elaboração de propostas. O filtro é o recurso decisivo, porque a mesma tela precisa servir a qualquer região e a qualquer pergunta.

O tempo disponível para análise é curto e fragmentado, pela acumulação de funções, e a pressão se concentra entre maio e julho, na abertura do Plano Safra, que é também um período de alta demanda de campo. Esse contexto exige telas que se expliquem sozinhas, regras de cálculo documentadas no próprio painel e uma carga de dados automatizada, que não dependa de uma pessoa específica.

2. Modelo de Dados

2.1. Modelo Dimensional

A modelagem dimensional seguiu os quatro passos propostos por Kimball: identificação do processo de negócio, definição do grão, identificação das dimensões e definição dos fatos.

O processo principal corresponde à contratação de operações de crédito rural do Pronaf por agricultores familiares do Rio Grande do Sul, analisada em conjunto com o reconhecimento federal de desastres por município. Essa abordagem resultou em duas tabelas fato relacionadas por dimensões conformadas, organizadas em um esquema estrela (Figura 1).

O grão da tabela *fato_contratacao_pronaf* corresponde a uma combinação única de mês de emissão, município, subprograma, finalidade, atividade, modalidade, produto, fonte de recursos, instituição financeira, categoria do emitente, instrumento de crédito e situação climática da safra. A agregação mensal foi escolhida por razões de desempenho e aderência aos objetivos analíticos, das 1.288.015 operações originais, foram obtidas 409.304 linhas, mantendo os eixos de análise previstos no painel. Como não há perguntas de negócio que exijam a análise individual dos contratos, esse detalhamento foi preservado na camada de staging para reprocessamentos e testes de homologação.

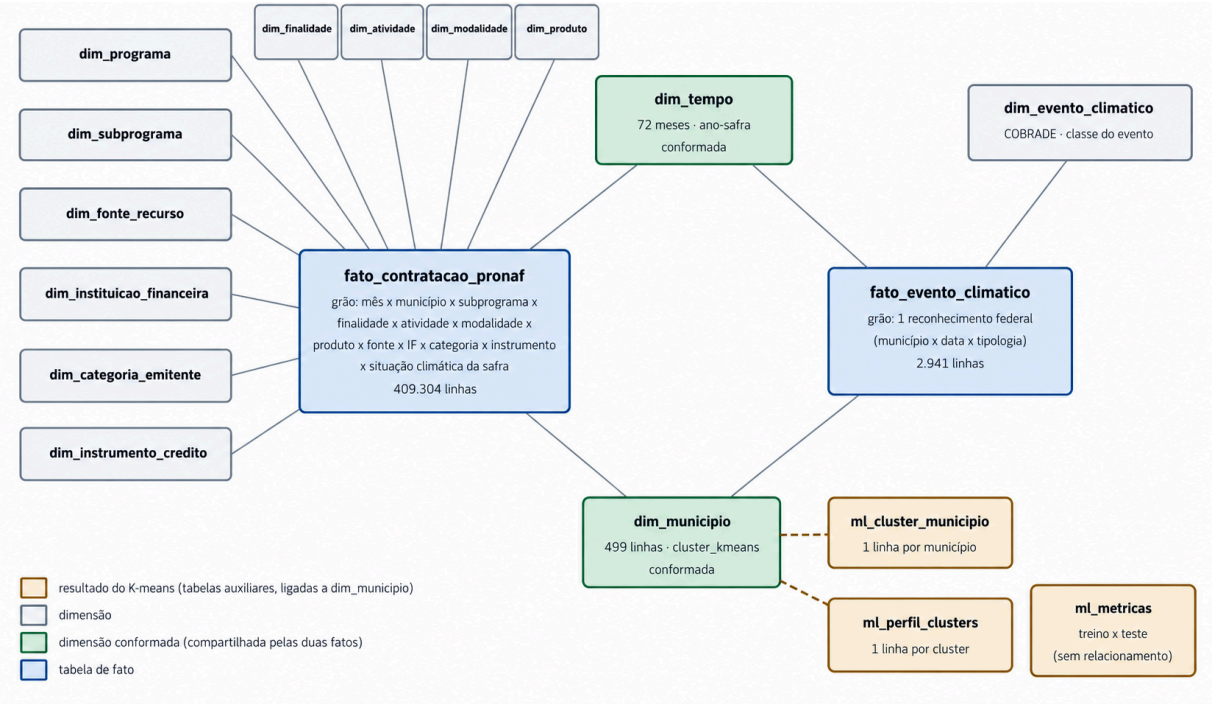
A tabela fato secundária, *fato_evento_climatico*, possui uma linha por reconhecimento federal de desastre, identificado por município, data e tipologia COBRADE, totalizando 2.941 registros no período analisado.

As dimensões *dim_tempo* e *dim_municipio* são conformadas, ou seja, compartilhadas pelas duas tabelas fato, permitindo cruzar informações de crédito rural e eventos climáticos. Assim, é possível, por exemplo, analisar os valores contratados e os reconhecimentos de desastres em uma mesma região.

Todas as dimensões utilizam chaves substitutas (surrogate key) inteiras sequenciais, preservam as chaves naturais de origem e incluem um registro “Não informado” para evitar chaves órfãs, exceto a *dim_tempo* e a *evento_climatico* que não possuem esse registro. Adotou-se a estratégia de dimensão de mudança lenta do tipo 1, com sobrescrita dos atributos, pois os cadastros do Banco Central são estáveis no período e o projeto não exige histórico de alterações dimensionais. Por fim, os resultados do modelo de aprendizado de máquina (Seção 4.2) foram incorporados à *dim_municipio* como atributo. Além de serem disponibilizados em três tabelas auxiliares, onde *ml_cluster_municipio* é ligada à *dim_municipio* pelo

código do município, *ml_perfil_clusters* que é ligada pelo rótulo do cluster e *ml_metricas*, sem relacionamento, que alimenta os cartões e a tabela de validação da aba Machine Learning.

Figura 1: Modelo dimensional, esquema em estrela



Fonte: elaborado pelo autor a partir do modelo de dados do Power BI.

2.2. Fatos e Dimensões

A Tabela 1 descreve as medidas e atributos da tabela de fato principal, já a Tabela 2, os da fato de eventos climáticos e por fim, a Tabela 3, as dimensões do modelo.

Tabela 1: Medidas e atributos de *fato_contratacao_pronaf*

Medida / atributo	Tipo	Regra de cálculo (origem)
qtde_contratos	Aditiva	Contagem de operações (REF_BACEN + NU_ORDEM) no grão
valor_contratado	Aditiva	Soma de VL_PARC_CREDITO
area_financiada_ha	Aditiva	Soma de VL_AREA_FINANC
vl_taxa_ponderada	Aditiva auxiliar	Soma de (VL_JUROS × VL_PARC_CREDITO); serve ao cálculo da taxa média ponderada

Medida / atributo	Tipo	Regra de cálculo (origem)
flag_safra_afetada	Dimensão degenerada (0/1)	1 quando o município teve reconhecimento de seca/estiagem ou de excesso hídrico dentro do ano-safra da emissão
tipo_evento_safra	Dimensão degenerada	Seca, Excesso hídrico, Ambos, Sem evento
sk_tempo, sk_municipio e demais 10 colunas sk_*	Chaves estrangeiras	Chave substituta de cada dimensão, uma por dimensão ligada à fato
ano_mes, cd_municipio, cd_programa e demais 9 códigos	Chaves naturais de origem	Códigos do SICOR mantidos para rastreabilidade e homologação, redundantes em relação às dimensões

Fonte: elaborado pelo autor a partir do SICOR/BCB e do Atlas Digital de Desastres.

Além das medidas e das dimensões degeneradas, a fato contém as doze chaves substitutas que a ligam às dimensões e os doze códigos naturais de origem, mantidos por rastreabilidade, pois eles permitem conferir a fato diretamente contra os arquivos do SICOR, sem passar pelas dimensões, o que foi usado na homologação.

A tabela *fato_evento_climatico* tem como grão um reconhecimento federal de desastre, identificado por município, data e tipologia COBRADE, e reúne 2.941 registros no período. Seus atributos estão descritos na Tabela 2. Diferentemente da fato de contratação, ela não é agregada, isto é, cada linha corresponde a um registro do Atlas Digital, o que preserva o protocolo e o status de cada reconhecimento.

Tabela 2: Medidas e atributos de fato_evento_climatico

Medida / atributo	Tipo	Regra de cálculo (origem)
qtde_reconhecimentos	Aditiva	Valor 1 por registro, a soma dá o número de reconhecimentos
prejuizo_agricultura	Aditiva	Prejuízo privado declarado na agricultura (R$)
prejuizo_pecuaria	Aditiva	Prejuízo privado declarado na pecuária (R$)
prejuizo_privado_total	Aditiva	Prejuízo privado total declarado (R$)

afetados_seca	Semiaditiva	Pessoas afetadas por seca ou estiagem. Somável entre municípios, ao longo do tempo, a soma pode contar a mesma pessoa mais de uma vez
danos_humanos	Semiaditiva	Total de danos humanos diretos declarados; mesma ressalva de afetados_seca
data	Dimensão degenerada	Data do evento reconhecido
ano_safra	Dimensão degenerada	Ano-safra (julho a junho) derivado da data do evento, liga o evento à flag da fato de contratação
protocolo	Dimensão degenerada	Identificador do processo de reconhecimento
status	Dimensão degenerada	Status do reconhecimento, só são carregados registros “Reconhecido”
sk_tempo, sk_municipio, sk_evento_climatico	Chaves estrangeiras	Chave substituta de cada dimensão (dim_tempo, dim_municipio e dim_evento_climatico)
cd_municipio	Chave natural de origem	Código IBGE de 7 dígitos, mantido para rastreabilidade e para o cruzamento com a fato de contratação

Fonte: elaborado pelo autor a partir do Atlas Digital de Desastres no Brasil (S2iD)

A tabela classifica “afetados_seca” e “danos_humanos” como semiaditivas, e não como aditivas como os prejuízos, pois se o mesmo município teve duas estiagens reconhecidas na safra, as mesmas pessoas podem aparecer nos dois registros, e a soma às conta duas vezes.

A seguir são listadas as dimensões com suas chaves e atributos.

Tabela 3: Dimensões do modelo

Dimensão	Chave natural	Principais atributos	Fato(s)
dim_tempo	ano_mes	data, ano, mês, trimestre, semestre, ano_safra, mes_safra, periodo_safra e rótulo do mês da safra	Ambas (conformada)
dim_municipio	cd_municipio (IBGE)	nome, mesorregião, região intermediária, região imediata, cluster_kmeans e localização para o mapa	Ambas (conformada)

Dimensão	Chave natural	Principais atributos	Fato(s)
dim_programa	cd_programa	descrição do programa de crédito rural	Contratação
dim_subprograma	cd_subprograma	linha do Pronaf (custeio, Mais Alimentos, Agroindústria, Mulher, Jovem etc.)	Contratação
dim_finalidade	—	Custeio, Investimento , Comercialização, Industrialização	Contratação
dim_atividade	—	Agrícola, Pecuária	Contratação
dim_modalidade	—	modalidade do empreendimento financiado	Contratação
dim_produto	—	produto financiado (soja, milho, bovinos, trigo, uva etc.)	Contratação
dim_fonte_recurso	cd_fonte_recurso	fonte de recursos da operação	Contratação
dim_instituicao_financeira	cnpj_if	nome da instituição e grupo (coluna calculada no Power BI que reúne, por lista de nomes, as cooperativas dos sistemas Sicredi, Cresol e Sicoob e identifica Banco do Brasil e Banrisul	Contratação
dim_categoria_emitente	cd_categoria_emitente	categoria do emitente da operação	Contratação
dim_instrumento_credito	cd_instrumento	instrumento de crédito utilizado	Contratação
dim_evento_climatico	cobrade + tipologia	tipologia COBRADE, grupo, classe do evento (Seca, Excesso hídrico, Tempestade, Outro)	Evento climático

Fonte: elaborado pelo autor.

As dimensões, finalidade, atividade, modalidade e produto resultam da decomposição do código de empreendimento do SICOR, que é hierárquico. A decomposição em quatro eixos independentes permite consultas do tipo "custeio de soja" ou "investimento em leite", que seriam impossíveis com o código concatenado. Uma tabela-ponte entre o código de empreendimento e as quatro descrições é mantida na camada de staging.

O agrupamento das instituições financeiras merece registro, no SICOR, cada cooperativa singular tem CNPJ próprio, o que fragmenta o sistema cooperativo em centenas de linhas. O atributo de grupo reúne as cooperativas de um mesmo sistema e torna possível comparar a participação de Sicredi, Cresol e bancos em igualdade de condições.

3. Integração, Tratamento e Carga de Dados

3.1. Fontes de Dados

A base principal selecionada foi o SICOR, do Banco Central do Brasil, por reunir registros censitários das operações de crédito rural do país, com granularidade por operação e atributos como localização, período, finalidade, atividade, produto financiado, instituição financeira e valores. Essas características favorecem a modelagem dimensional proposta. Além disso, os dados são abertos, atualizados mensalmente e acompanhados de tabelas de domínio que permitem atribuir significado aos códigos registrados.

A base foi complementada pelo Atlas Digital de Desastres no Brasil, que reúne reconhecimentos federais de desastres registrados no S2iD, e pela API de localidades do IBGE. A identificação comum dos municípios pelo código IBGE e a referência temporal permitem integrar as três fontes por meio de dimensões conformadas.

O período selecionado, das safras 2019/2020 a 2024/2025 (julho de 2019 a junho de 2025), contempla 72 meses de histórico.

Os detalhes das fontes e dados utilizados são descritos na tabela a seguir.

Tabela 4: Fontes de dados

Fonte / arquivo	Origem	Conteúdo e colunas utilizadas	Destino no modelo
SICOR_OPERACAO_BASICA_ESTADO_<ano>.gz (2019 a 2025)	Banco Central do Brasil	Uma linha por operação: REF_BACEN, NU_ORDEM, CD_ESTADO, DT_EMISSAO, CD_PROGRAMA, CD_SUBPROGRAMA, CD_FONTE_RECURSO, CNPJ_IF, CD_CATEG_EMITENTE, CD_INST_CREDITO, CD_EMPREENDIMENTO, VL_PARC_CREDITO, VL_JUROS, VL_AREA_FINANC	Staging → *fato_contratacao_pronaf*
SICOR_COMPLEMENTO_OPERACAO_BASICA.gz	Banco Central do Brasil	REF_BACEN, NU_ORDEM, CD_IBGE_MUNICIPIO	Staging → chave de município

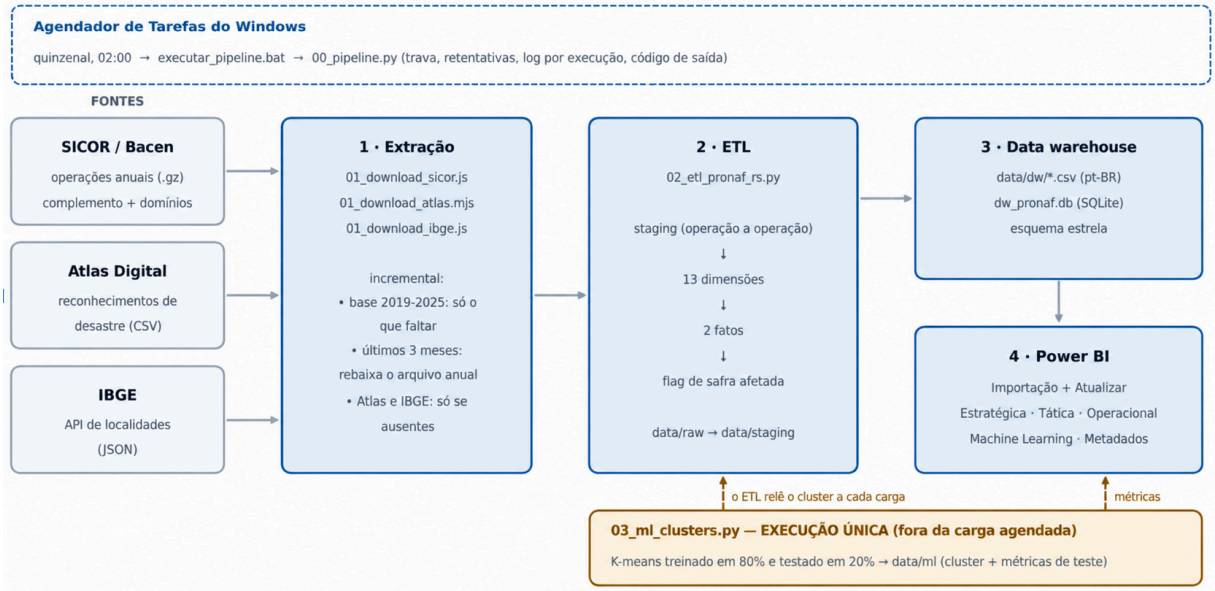
Fonte / arquivo	Origem	Conteúdo e colunas utilizadas	Destino no modelo
Tabelas de domínio (Programa, SubProgramas, FonteRecursos, CategoriaEmitente, InstrumentoCredito, Empreendimento, SICOR_LISTA_IFS)	Banco Central do Brasil	Código e descrição de cada eixo	Dimensões descritivas
Atlas Digital de Desastres no Brasil (extração do RS)	Ministério da Integração e do Desenvolvimento Regional (MIDR) / S2iD	Código do município, data do evento, COBRADE, grupo, tipologia, status, prejuízos declarados e afetados	dim_evento_climatico, fato_evento_climatico, flag de safra afetada
API de localidades	IBGE	Identificador, nome, mesorregião, região intermediária e região imediata dos 497 municípios do RS	dim_municipio

Fonte: elaborado pelo autor.

3.2. Processos de Integração e Carga (ETL)

O processo de integração foi implementado com ferramentas de custo nulo e é composto por três scripts de extração em JavaScript com Node.js, um script de transformação e carga em Python e um orquestrador, também em Python, que os executa em sequência. A escolha por código, em vez de ferramenta gráfica, atende à restrição de custo da organização e garante que todo o processo seja versionado e reproduzível. A Figura 2 apresenta o fluxo completo e a Tabela 5, as etapas executadas pelo orquestrador.

Figura 2: Fluxo de integração, carga e agendamento



Fonte: elaborado pelo autor.

Tabela 5: Etapas da carga automatizada (script 00_pipeline.py)

#	Etapa	Script	Quando executa	Em caso de falha
1	Base histórica do SICOR	01_download_sicor.js	Somente se algum arquivo da janela 2019–2025 estiver ausente (na prática, apenas na primeira carga)	Interrompe a carga
2	Atualização dos últimos três meses	01_download_sicor.js --force	Toda execução: rebaixa o(s) arquivo(s) anual(is) que contêm os três meses mais recentes, o complemento e as tabelas de domínio	Registra aviso e segue com os arquivos existentes
3	Atlas Digital	01_download_atlas.mjs	Somente se a pasta do Atlas estiver vazia	Interrompe a carga
4	Municípios do IBGE	01_download_ibge.js	Somente se a pasta do IBGE estiver vazia	Interrompe a carga
5	Transformação e carga	02_etl_pronaf_rs.py	Toda execução (carga total idempotente)	Interrompe a carga

Fonte: elaborado pelo autor.

A extração dos dados é realizada de forma incremental. Como o Banco Central disponibiliza arquivos anuais, atualizados a cada nova divulgação, a atualização dos períodos mais recentes é feita por meio do novo download do arquivo correspondente ao ano corrente. Para garantir a integridade dos dados brutos, os arquivos são inicialmente armazenados com uma extensão temporária e

substituem as versões anteriores somente após a conclusão bem-sucedida do download. Já as bases do Atlas e do IBGE, cuja atualização é menos frequente, são baixadas apenas quando ainda não estão disponíveis localmente.

O processo de transformação e carga, executado por um script, compreende sete etapas principais:

1. leitura das tabelas de domínio e identificação dinâmica dos códigos cujas descrições correspondem ao Pronaf, excluindo-se o Pronamp;
2. leitura dos arquivos anuais em blocos, com aplicação progressiva dos filtros de unidade da federação, programa, valor positivo e período de análise. Essa estratégia permite processar arquivos de grande volume, da ordem de gigabytes, sem sobrecarregar a memória;
3. leitura do arquivo complementar, mantendo-se apenas as chaves das operações previamente selecionadas, para associar cada operação ao município do imóvel;
4. geração das tabelas dimensionais, incluindo a *dim_tempo*, produzida programaticamente com atributos de ano-safra, e a *dim_municipio*, construída a partir da API do IBGE;
5. desmembramento do código de empreendimento nas dimensões de finalidade, atividade, modalidade e produto, utilizando uma tabela-ponte.
6. cálculo da flag de safra afetada pelo cruzamento entre o município de cada operação e os registros de reconhecimento de desastres do Atlas, considerando a correspondência dentro do mesmo ano-safra;
7. consolidação dos dados conforme o grão previamente definido, geração das tabelas de fatos e exportação dos resultados em arquivos CSV, no padrão brasileiro de formatação, e em um banco de dados SQLite.

As regras de negócio aplicadas durante a transformação dos dados, também documentadas na aba de metadados do painel, são descritas a seguir. O ano-safra compreende o período de julho a junho do ano seguinte, em consonância com o calendário do Plano Safra, sendo julho considerado o primeiro mês da safra.

A seleção das operações considera os seguintes critérios: unidade da federação igual a RS, programa pertencente ao conjunto de códigos do Pronaf, valor da parcela de crédito superior a zero e data de emissão entre 1º de julho de 2019 e 30 de junho de 2025. A aplicação do filtro temporal resultou na exclusão de 168.336 operações.

A classificação de safra afetada é atribuída quando o município associado à operação apresenta reconhecimento federal de desastre por seca ou estiagem, ou por excesso hídrico (incluindo inundação, enxurrada, alagamento e chuvas intensas) dentro do mesmo ano-safra da emissão do crédito. Eventos de tempestade, como granizo e vendaval, não acionam essa classificação, mas permanecem registrados na tabela de fatos de eventos climáticos. Por fim, são considerados na carga apenas os reconhecimentos cujo status seja “Reconhecido”.

Uma decisão relevante de modelagem foi definir a flag de safra afetada no nível do ano-safra, e não do mês de emissão do crédito. A abordagem anterior associava os eventos climáticos apenas às operações emitidas no mesmo mês, desconsiderando que seus efeitos podem se estender pelo restante da safra, como nos casos de custeio de replantio, prorrogações e concessão de crédito emergencial. Com a regra adotada, todas as operações do município na safra correspondente são classificadas como afetadas. Já os efeitos defasados, nos quais um evento climático ocorrido em uma safra repercute no custeio da seguinte, são analisados separadamente por meio da medida *Var. % Custeio Safra Seguinte*, apresentada em um gráfico específico da aba “Tático · Climático”.

Para assegurar a qualidade e a integridade dos dados, foram implementadas quatro medidas de tratamento. Os códigos dos municípios são padronizados para sete dígitos, com preenchimento de zeros à esquerda, antes das operações de junção, garantindo a compatibilidade entre fontes. As operações vinculadas a imóveis localizados fora do Rio Grande do Sul são mantidas em uma linha específica da dimensão de município, sem descarte dos registros. Da mesma forma, operações sem correspondência no arquivo complementar são associadas à categoria “Não informado”, preservando os totais estaduais. Por fim, o script registra em log a quantidade de linhas descartadas em cada filtro, o percentual de operações sem identificação municipal e o número de chaves órfãs por dimensão. Na carga final, não foram identificadas chaves órfãs.

O requisito funcional de integração de tratamento e carga de dados é atendido por meio de dois mecanismos complementares. O primeiro consiste em uma carga total idempotente, na qual cada execução relê os dados brutos, reconstrói as dimensões e tabelas de fatos e substitui os dados de destino. Dessa forma, desde que as fontes mantenham uma estrutura compatível de colunas, eventuais atualizações podem ser incorporadas sem alterações no código. O

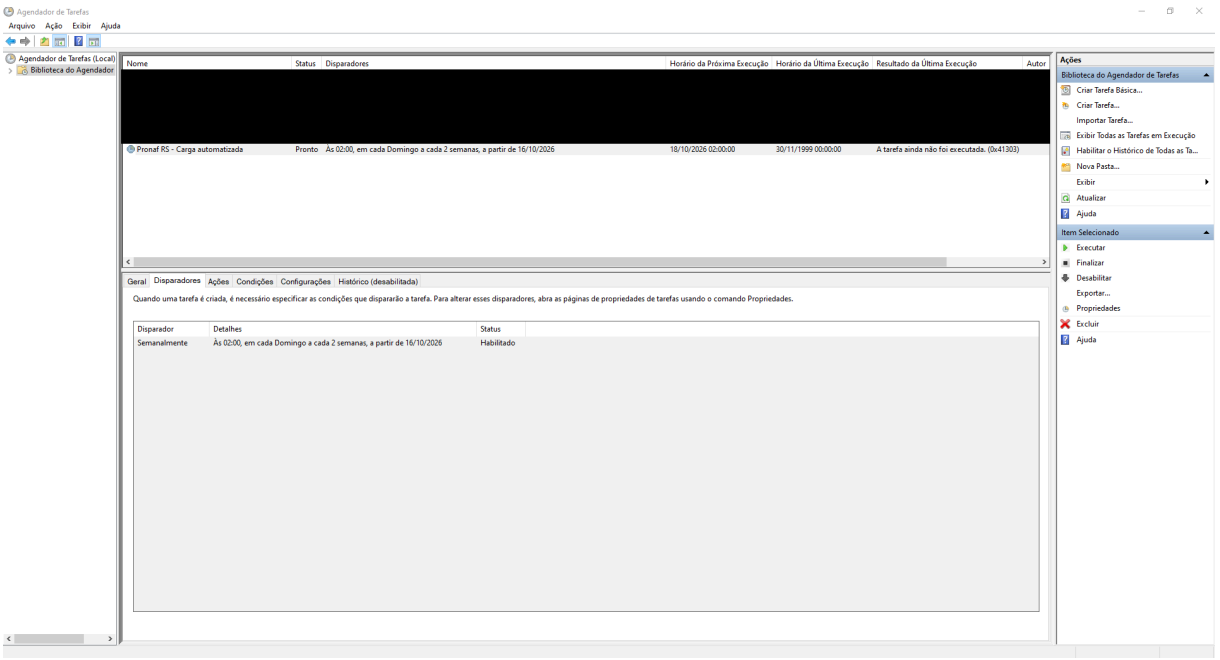
mapeamento de colunas por identificação de nomes equivalentes também contribui para a tolerância a variações de nomenclatura. O segundo mecanismo é a automação da execução, realizada pelo Agendador de Tarefas do Windows, configurado para iniciar o orquestrador quinzenalmente às 2h. Caso o computador esteja desligado no horário programado, a execução é iniciada quando ele é ligado novamente, conforme a configuração da tarefa.

O orquestrador registra cada execução em log com carimbo de data e hora, realiza novas tentativas em etapas que dependem de conexão de rede, utiliza um arquivo de trava para impedir execuções simultâneas e retorna ao agendador um código de saída que indica sucesso ou falha. Após a conclusão da carga, a atualização do modelo no Power BI permite refletir os dados processados no painel.

O modelo de aprendizado de máquina é mantido independente da carga agendada. Seu treinamento ocorre uma única vez, e os resultados são armazenados em um arquivo específico, consultado pelo script de transformação a cada execução para preencher o atributo de cluster da dimensão de município. Assim, a reconstrução recorrente do data warehouse preserva o modelo treinado, sem exigir um novo treinamento a cada carga.

Quanto ao escopo temporal, o conjunto de dados contempla uma janela fixa de julho de 2019 a junho de 2025. Embora a extração incremental mantenha os arquivos brutos atualizados conforme as divulgações do Banco Central, essas atualizações não modificam os indicadores do painel enquanto as operações posteriores ao período definido forem descartadas na transformação. Para ampliar a análise, basta ajustar a data final nos parâmetros do processo. A data apresentada no rodapé das abas do painel e na aba Metadados "*Última carga do ETL: 01/10/2026"* é preenchida manualmente e identifica a carga utilizada na geração dos resultados apresentados neste relatório. O histórico das execuções automatizadas, por sua vez, é mantido nos logs do orquestrador.

Figura 3: Execução automatizada da carga



Fonte: elaborado pelo autor.

O resultado da carga é apresentado na Tabela 6.

Tabela 6: Volumetria da carga

Item	Resultado
Operações selecionadas (RS, Pronaf, janela)	1.288.015
Operações descartadas por estarem fora da janela	168.336
Valor contratado	R$ 73,85 bilhões
Linhas da fato_contratacao_pronaf (grão agregado)	409.304
Reconhecimentos de desastre na fato_evento_climatico	2.941
Dimensões	13 (12 ligadas à fato principal)
Período coberto	jul/2019 a jun/2025: 6 safras, 72 meses
Municípios na dimensão	497 + "Não informado" + "Fora do RS"
Municípios com contratação no período	495
Chaves órfãs	0
Operações sem município na origem	12,1% das operações (17,4% do valor)
Duração da carga agendada	aproximadamente 10 minutos

Fonte: log de execução do processo de carga e modelo de dados do painel.

4. Camada de Apresentação

4.1 Dashboard

O dashboard foi desenvolvido no Microsoft Power BI, utilizando o modo de importação para carregar as tabelas CSVs produzidas pelo processo de carga. Sua estrutura contempla seis abas, acessíveis por meio de um menu lateral de navegação, conforme apresentado na Tabela 7. As quatro primeiras são dedicadas aos níveis de decisão definidos no regulamento e compartilham um painel de filtros. A quinta apresenta os resultados da análise de aprendizado de máquina, enquanto a sexta reúne a documentação e os metadados do painel.

Tabela 7: Abas do painel

Aba	Nível	Conteúdo	Momento de uso
Visão estratégica	Estratégico	10 indicadores em cartões, mapa de bolhas por município (cor = cluster) e gráfico combinado de valor e variação por safra	Planejamento do ciclo
Tático · Financeiro	Tático	6 gráficos: série mensal, sazonalidade, instituições financeiras, produtos, composição por finalidade e ticket × taxa por subprograma	Preparação do trabalho de campo
Tático · Climático	Tático	4 visualizações: custeio por safra e evento, reconhecimentos por classe, calendário de contratação e prejuízo × custeio na safra seguinte	Preparação do trabalho de campo e avaliação do risco climático
Operacional	Operacional	3 tabelas: resumo por município, detalhamento das contratações e eventos climáticos reconhecidos	Elaboração de propostas e contato com parceiros
Machine Learning	Análise avançada	4 cartões de validação, tabela de métricas, dispersão dos municípios em componentes principais e distribuição treino × teste	Definição de prioridades por perfil de município
Metadados	Documentação	Dicionário com 46 registros, filtrável por categoria	Consulta às regras de cálculo

Fonte: elaborado pelo autor.

A aba **Visão Estratégica** busca responder à seguinte questão: qual é a dimensão e a distribuição do mercado de crédito rural do Pronaf no Rio Grande do

Sul? Para isso, reúne dez indicadores em cartões, um mapa de bolhas por município e um gráfico combinado da evolução por safra. No mapa, o tamanho das bolhas representa o valor contratado, enquanto as cores identificam os clusters de municípios. O gráfico combinado apresenta o valor contratado por safra em colunas e sua variação percentual em relação à safra anterior em linha. Os indicadores e suas respectivas regras de cálculo são detalhados na Tabela 8, com os valores de referência obtidos sem a aplicação de filtros.

Tabela 8: Indicadores da visão estratégica

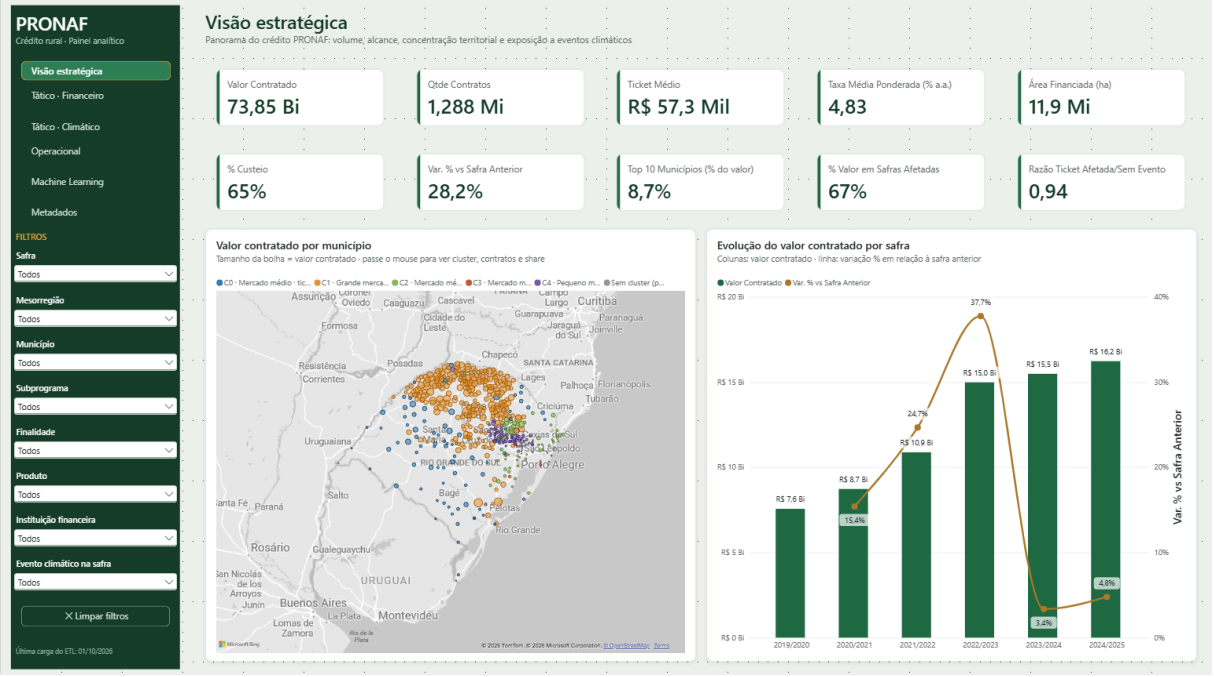
#	Indicador	Regra de cálculo	Valor sem filtro
1	Valor contratado	Soma de valor_contratado	R$ 73,85 bi
2	Contratos	Soma de qtde_contratos	1.288.015
3	Ticket médio	Valor contratado ÷ contratos	R$ 57,3 mil
4	Taxa média ponderada	Σ(juros × valor) ÷ Σ valor	4,83% a.a.
5	Área financiada	Soma de area_financiada_ha	11,9 milhões de ha (acumulada nas seis safras)
6	% Custeio	Valor de custeio ÷ valor contratado	65%
7	Variação % vs. safra anterior	(valor da safra − valor da safra anterior) ÷ valor da safra anterior	28,2%; por safra, 2024/2025: +4,8%
8	Top-10 municípios (% do valor)	Σ dos 10 maiores municípios ÷ Σ dos registros com município (exclui "Não informado")	8,7%
9	% do valor em safras afetadas	Valor com flag_safra_afetada = 1 ÷ valor contratado total (inclui operações sem município)	67%
10	Razão ticket safra afetada / sem evento	Ticket médio com flag = 1 ÷ ticket médio com flag = 0 (o grupo flag = 0 inclui as operações sem município)	0,94

Fonte: painel desenvolvido pelo autor. Medidas implementadas em DAX.

Três indicadores exigem atenção quanto à interpretação. O indicador 7 foi concebido para análise com uma safra selecionada. Na ausência de filtros, a medida compara o valor acumulado das seis safras analisadas (R$ 73,85 bilhões) com a soma dos valores das safras imediatamente anteriores a cada uma delas (R$ 57,62 bilhões), resultando na variação de 28,2% apresentada no cartão. Quando uma safra específica é selecionada, o indicador passa a exibir sua variação individual, como os +4,8% registrados em 2024/2025. A evolução completa dessas variações pode ser observada na linha do gráfico combinado.

Os indicadores 9 e 10, por sua vez, utilizam como referência o total estadual, que inclui as operações sem município identificado, responsáveis por 17,4% do valor contratado. Como não é possível relacionar essas operações aos reconhecimentos de desastres, elas são classificadas no grupo “Sem evento”. Essa inclusão reduz o percentual apresentado no indicador 9 e eleva o ticket médio do grupo sem evento no indicador 10. Portanto, ambos devem ser interpretados como medidas calculadas sobre o total estadual, e não apenas sobre o conjunto de operações com localização identificada.

Figura 4: Aba Visão estratégica



Fonte: painel desenvolvido pelo autor.

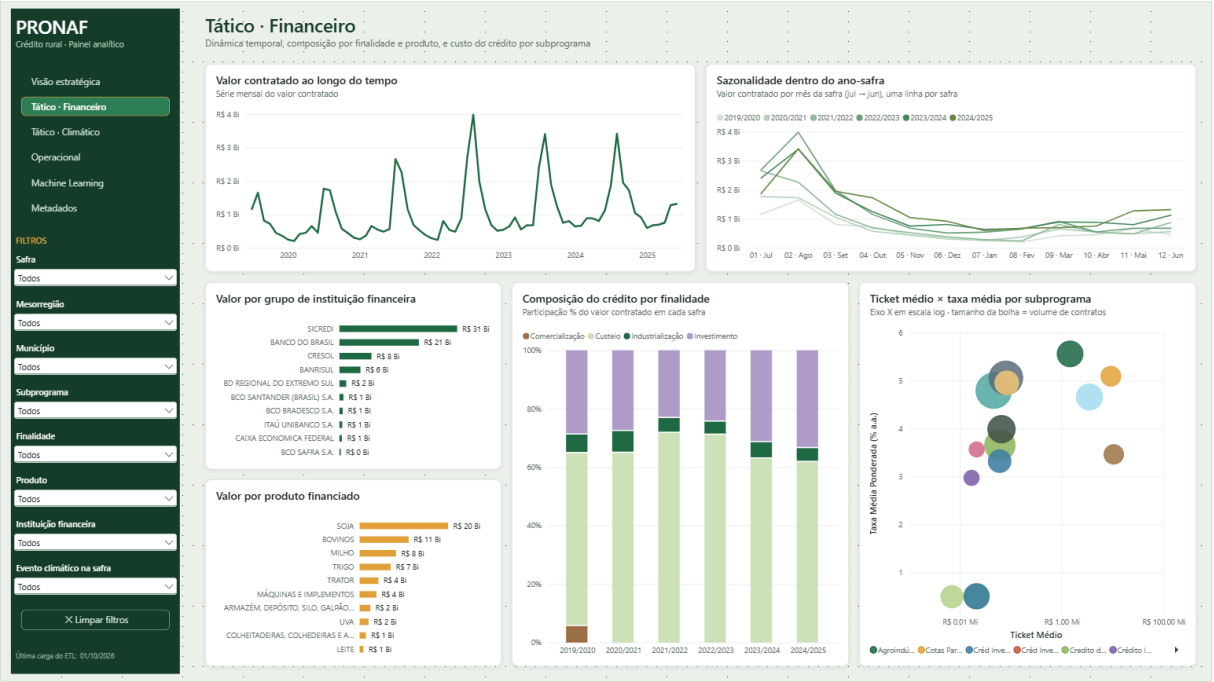
As duas abas táticas abordam a evolução temporal do crédito, sua composição e sua relação com os eventos climáticos. Ao todo, apresentam dez visualizações, com variáveis numéricas ao longo do tempo, variáveis numéricas por categoria, relações entre duas variáveis numéricas e análises que combinam variáveis numéricas com duas variáveis categóricas, tudo está detalhado na Tabela 9. Essa estrutura permite explorar diferentes perspectivas dos dados e investigar padrões associados ao comportamento do crédito rural e à ocorrência de eventos climáticos.

Tabela 9: Visualizações das visões táticas

#	Aba	Visualização	Tipo de gráfico	Combinação de variáveis
1	Financeiro	Valor contratado ao longo do tempo	Linhas	Numérica × tempo (mensal)
2	Financeiro	Sazonalidade dentro do ano-safra	Linhas múltiplas	Numérica × mês da safra × safra
3	Financeiro	Valor por grupo de instituição financeira	Barras horizontais	Numérica × categórica
4	Financeiro	Valor por produto financiado	Barras horizontais	Numérica × categórica
5	Financeiro	Composição do crédito por finalidade	Colunas 100% empilhadas	Numérica × duas categóricas
6	Financeiro	Ticket médio × taxa média por subprograma	Dispersão (eixo X em escala log; bolha = volume de contratos)	Duas numéricas + categórica
7	Climático	Crédito de custeio por safra e evento climático	Colunas agrupadas	Numérica × duas categóricas
8	Climático	Reconhecimentos de desastres por classe de evento	Área empilhada	Numérica × categórica (fato de eventos)
9	Climático	Calendário de contratação	Matriz com formatação condicional (mapa de calor)	Numérica × duas categóricas
10	Climático	Prejuízo agropecuário × custeio na safra seguinte	Dispersão animada (eixo de reprodução por safra)	Duas numéricas × tempo (cruza as duas fatos); eixo Y em razão (1 = +100%)

Fonte: painel desenvolvido pelo autor.

Figura 5: Aba Tático · Financeiro



Fonte: painel desenvolvido pelo autor.

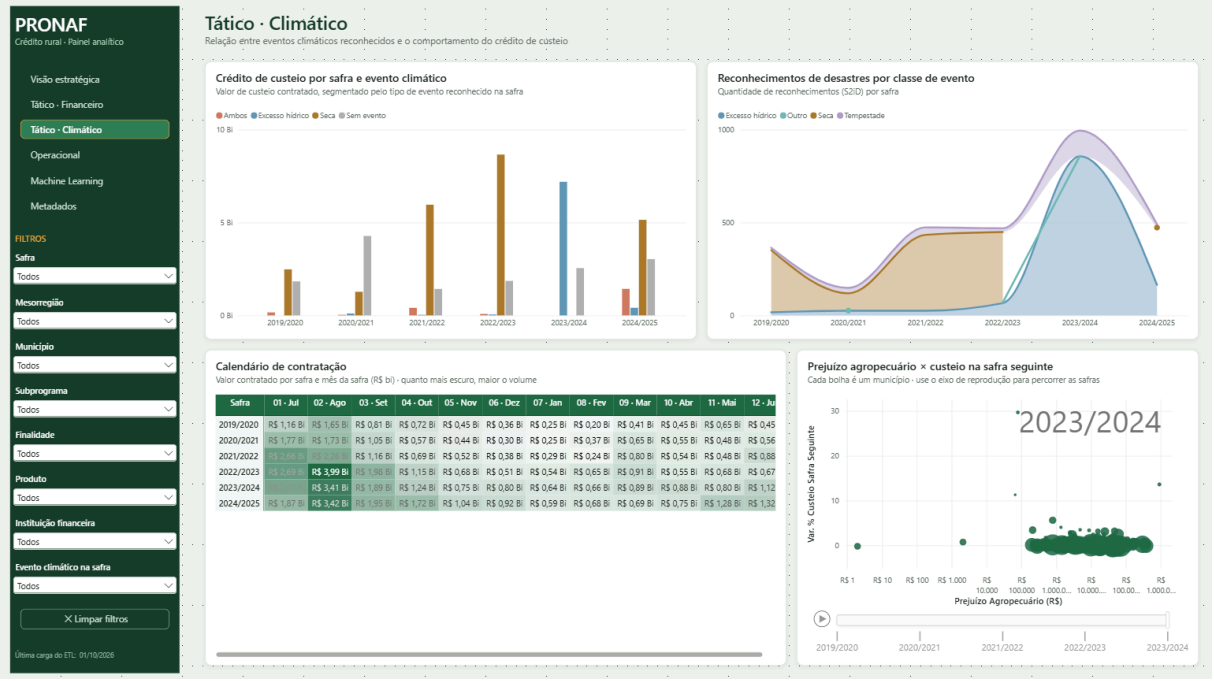
A interpretação da aba **Tático · Financeiro** requer atenção a quatro convenções. Nos gráficos de instituições financeiras e de produtos, os rótulos apresentam os valores arredondados para bilhões inteiros, enquanto os percentuais mencionados neste relatório foram calculados com base nos valores originais, sem arredondamento. No gráfico de instituições financeiras, são exibidos os grupos de principais bancos atuantes no setor agrícola do RS definidos no modelo (Sicredi, Cresol, Sicoob, Banco do Brasil e Banrisul), que podem ser expandidos para visualizar as instituições individuais. As demais instituições são identificadas conforme os nomes registrados no SICOR.

No gráfico de composição por finalidade, a categoria “Comercialização” aparece somente na safra 2019/2020, representando cerca de 6% do valor contratado e reduzindo, consequentemente, a participação relativa do custeio nesse período.

Por fim, no gráfico de dispersão do ticket médio por taxa média, o eixo horizontal utiliza escala logarítmica. O tamanho das bolhas representa o logaritmo da quantidade de contratos, e não seu valor absoluto, permitindo manter visíveis os subprogramas com menor volume de operações. Essa transformação reduz a diferença visual entre as bolhas em relação às diferenças reais de volume. A

identificação de cada subprograma é disponibilizada por meio da interação com o gráfico, ao posicionar o cursor sobre a respectiva bolha.

Figura 6: Aba Tático · Climático



Fonte: painel desenvolvido pelo autor.

A interpretação da aba **Tático · Climático** requer atenção a três convenções. No gráfico de crédito de custeio por safra e evento climático, a categoria “Sem evento” inclui também as operações sem município identificado, que não podem ser relacionadas aos registros do Atlas. Essa condição explica a presença de aproximadamente R$ 2,6 bilhões nessa categoria na safra 2023/2024, período em que 467 municípios registraram reconhecimento de desastre por excesso hídrico. No gráfico de reconhecimentos de desastres por classe de evento, a área correspondente à seca é interrompida na safra 2023/2024, pois não houve reconhecimentos dessa natureza no período, enquanto o registro de 2024/2025 aparece como um ponto isolado. Já no gráfico de dispersão, o eixo vertical apresenta a variação do custeio na safra seguinte em forma de razão, na qual 0,5 representa um aumento de 50% e 1 representa um aumento de 100%. O eixo horizontal, por sua vez, utiliza escala logarítmica.

A aba **Operacional** complementa as análises agregadas com informações detalhadas para consulta. Ela reúne três tabelas:

- O resumo por município, que apresenta mesorregião, região imediata, cluster, quantidade de contratos, valor contratado, ticket médio, participação, percentual de custeio e reconhecimentos de desastres;
- O detalhamento das contratações, com registros por safra, mês, município, subprograma, finalidade, produto e instituição financeira;
- A relação de eventos climáticos reconhecidos, contendo data, município, tipologia, classe, grupo, status, protocolo, número de afetados e prejuízo.

Todas as tabelas permitem ordenação e exportação dos dados, apoiando consultas detalhadas e a elaboração de propostas comerciais.

Figura 7: Aba Operacional



Fonte: painel desenvolvido pelo autor.

A integração entre as abas é implementada por meio de oito segmentações de dados baseadas nas dimensões de safra, mesorregião, município, subprograma, finalidade, produto, instituição financeira e evento climático na safra. Esses filtros são sincronizados entre as quatro abas analíticas, permitindo a aplicação consistente dos critérios de seleção, e complementados por um botão para limpar os filtros.

A sincronização garante que as seleções realizadas em uma aba sejam aplicadas automaticamente nas demais. Por exemplo, ao selecionar uma safra na

aba Tático · Financeiro, os cartões da Visão Estratégica e as tabelas da aba Operacional são atualizados sem necessidade de ações adicionais. Como as duas tabelas de fatos compartilham as dimensões de tempo e município, os filtros também integram as análises de crédito e de eventos climáticos. Assim, a seleção de uma mesorregião restringe simultaneamente os contratos e os reconhecimentos de desastres apresentados no painel. Além disso, o cluster atribuído a cada município é representado tanto pelas cores do mapa quanto por uma coluna específica na tabela de resumo municipal, facilitando a associação entre as diferentes visualizações.

Aba **Metadados** reúne a documentação do painel em 46 registros, filtráveis por categoria. O conteúdo contempla 28 medidas de negócio, acompanhadas de suas regras de cálculo e fontes. Oito regras de negócio, referentes à janela temporal, ao ano-safra, aos filtros de origem, à classificação climática, aos tipos de evento, ao grão das tabelas, ao tratamento da categoria “Não informado” e ao agrupamento de instituições financeiras. Além de cinco fontes de dados, três limitações conhecidas e dois controles de carga. Estes últimos correspondem à data da última carga e ao registro de homologação, que sintetiza a verificação de plausibilidade dos resultados com base em divulgações externas, detalhada na Seção 5.

Figura 8: Aba Metadados



Categoria	Fonte	Item	Observação	Regra de cálculo / Definição
Controle	ETL	Última carga do ETL	Preencher a cada atualização	Data/hora da execução de etl_pronaf_rs.py
Controle	Relatório item 5	Homologação		Totais por safra conferidos com Sicredi (R$ 6,4 bi 2023/24 → DW 6,08 bi) e Banrisul (R$ 1,5 bi 2022/23 → DW 1,36 bi); diferenças de 5–9% por data de corte e valor liberado vs contratado
Fonte	API servicodados.ibge.gov.br	IBGE – Localidades		Nome, mesorregião, região intermediária e imediata dos 497 municípios do RS
Fonte	Banco Central do Brasil	SICOR – Complemento	Cobre apenas operações vinculadas a imóvel	CD_IBGE_MUNICIPIO por operação
Fonte	Banco Central do Brasil	SICOR – Tabelas de domínio		Programa, SubProgramas, FonteRecursos, CategoriaEmitente, InstrumentoCredito, Empreendimento, Lista de IFs
Fonte	https://atlasdigital.mdr.gov.br	Atlas Digital de Desastres no Brasil	Base RS, eventos 2019–2025; só status Reconhecido	Reconhecimentos federais (S2ID) por município, COBRADE, danos e prejuízos
Fonte	https://www.bcb.gov.br/estabilidadefinanceira/micrrural	SICOR – Operações básicas por estado	Dados abertos; atualização mensal	Banco Central do Brasil, arquivos anuais 2019–2025 (SICOR_OPERACAO_BASICA_ESTADO_<ano>.gz)
Limitação	Atlas Digital	Prejuízos do Atlas	Usar como ordem de grandeza	Valores autodeclarados pelos municípios no FIDE, sem auditoria
Limitação	Projeto	Causalidade		A relação clima × crédito é descritiva (mesmo município entre safras); não há inferência causal
Limitação	SICOR	Cobertura municipal	Análises por município usam 88% das operações (R$ 61 bi)	12,1% das operações sem município na origem
Medida	Atlas Digital	Afetados por Seca	Pessoas afetadas declaradas	Σ DH_AFETADOS_SECA_ESTIAGEM
Medida	Atlas Digital	Municípios com Reconhecimento		Contagem distinta de municípios com reconhecimento
Medida	Atlas Digital	Prejuízo Agropecuário (R$)	Prejuízo privado declarado pelo município no FIDE	Σ PEPR_AGRICULTURA_R + Σ PEPR_PECUARIA_R
Medida	Atlas Digital / S2iD (fato_evento_climatico)	Reconhecimentos	Um registro por município × evento	Contagem de reconhecimentos federais (status = Reconhecido)
Medida	Derivada	% Custeio		Valor Custeio ÷ Valor Contratado
Medida	Derivada	% Valor em Safras Afetadas		Valor em Safras Afetadas ÷ Valor Contratado
Medida	Derivada	HHI Municipal	Índice Herfindahl-Hirschman; < 100 = mercado muito pulverizado	Σ (share_i)² × 10.000 sobre municípios identificados
Medida	Derivada	Razão Ticket Afetada/Sem Evento	> 1 indica contratos maiores em safras afetadas	Ticket Médio Safra Afetada ÷ Ticket Médio Sem Evento
Medida	Derivada	Share do Município	Participação no mercado total; não soma 100% entre municípios identificados	Valor do município ÷ Valor Contratado total do RS (incl. Não informado)
Medida	Derivada	Tamanho (log contratos)	Só para tamanho de marcador em dispersão	LOG10(Qtde Contratos + 1)
Medida	Derivada	Ticket Médio	Média por contrato, não por produtor	Valor Contratado ÷ Qtde Contratos
Medida	Derivada	Ticket Médio Safra Afetada		Ticket Médio com flag_safra_afetada = 1
Medida	Derivada	Ticket Médio Sem Evento		Ticket Médio com flag_safra_afetada = 0
Medida	Derivada	Top 10 Municípios (% do valor)	Exclui Não informado; mede concentração	Σ valor dos 10 maiores municípios ÷ Σ valor de todos os municípios identificados
Medida	Derivada	Valor Custeio Safra Seguinte	Vazio para 2024/2025	Valor Custeio da safra seguinte a cada safra no contexto
Medida	Derivada	Valor por Hectare	Só faz sentido para custeio agrícola	Valor Contratado ÷ Área Financiada
Medida	Derivada	Valor Safra Anterior	Vazio para 2019/2020 (fora da janela)	Valor Contratado da safra imediatamente anterior a cada safra no contexto
Medida	Derivada	Var. % Custeio Safra Seguinte	Usado para relacionar prejuízo climático em t com custeio em t+1	(Valor Custeio Safra Seguinte − Valor Custeio) ÷ Valor Custeio
Medida	Derivada	Var. % vs Safra Anterior		(Valor Contratado − Valor Safra Anterior) ÷ Valor Safra Anterior

Fonte: painel desenvolvido pelo autor.

A aba **ML** (Machine Learning) também incorpora recursos de documentação. Nela, cada métrica de validação é acompanhada de uma coluna com sua interpretação, enquanto um painel lateral apresenta orientações para a leitura e compreensão dos resultados.

Considerando o painel em sua totalidade, são empregados onze tipos distintos de visualização, sendo eles: cartões, mapa de bolhas, gráfico combinado de colunas e linha, gráficos de linhas, barras horizontais, colunas 100% empilhadas, colunas agrupadas, área empilhada, dispersão, matriz e tabela.

As combinações de variáveis são contempladas em diferentes elementos do painel. A análise de uma variável numérica é realizada por meio dos cartões das abas Visão Estratégica e Machine Learning, já a análise de uma variável categórica ocorre na distribuição dos municípios por cluster, na aba Machine Learning. A relação entre duas variáveis numéricas é explorada nos gráficos de dispersão, enquanto as combinações de variáveis numéricas e categóricas são apresentadas nos gráficos de barras e colunas e na matriz.

A escolha dos recursos visuais também considerou a clareza na comparação dos dados. Por esse motivo, gráficos de pizza e de rosca foram deliberadamente evitados, uma vez que, na presença de mais de duas categorias, a comparação de proporções por comprimento tende a ser mais precisa do que aquela baseada em ângulos (FEW, 2013).

Por fim, com relação ao desempenho do painel, a definição do grão de agregação e a utilização do modo de importação no Power BI contribuem para manter os tempos de resposta do painel abaixo do limite de dez segundos estabelecido pelo regulamento.

4.2 Análises avançadas

A técnica de aprendizado de máquina adotada foi a clusterização pelo algoritmo K-means, implementado na biblioteca scikit-learn (PEDREGOSA et al., 2011). A escolha justifica-se por seu caráter não supervisionado, adequado a cenários em que não há uma variável-alvo previamente definida, e por permitir segmentar os municípios do Rio Grande do Sul em perfis comerciais que subsidiem a tomada de decisão.

Cada município foi descrito por nove atributos calculados a partir do data warehouse:

- Logaritmo do valor médio contratado por safra, que representa o tamanho do mercado;
- Ticket médio;
- Participação do custeio no valor contratado;
- Participação da atividade pecuária;
- Taxa de juros média ponderada;
- Participação das cooperativas de crédito, identificadas por nomes contendo Sicredi, Cresol ou Unicred;
- Coeficiente de variação do valor contratado entre safras, que mede a volatilidade da demanda;
- Número de safras com reconhecimento de seca ou excesso hídrico;
- Prejuízo agropecuário declarado por contrato.

Para reduzir a assimetria dos atributos com distribuição de cauda longa, aplicou-se a transformação logarítmica ao ticket médio e ao prejuízo por contrato. Em seguida, todas as variáveis foram padronizadas para média zero e desvio padrão unitário, evitando que diferenças de escala, especialmente as monetárias, distorcessem o cálculo das distâncias euclidianas. Dos 495 municípios com contratações no período analisado, 32 foram excluídos por apresentarem menos de cem contratos, quantidade considerada insuficiente para estimativas estáveis dos indicadores. Assim, a população elegível para a modelagem compreendeu 463 municípios.

Para avaliar a capacidade de generalização do modelo, os municípios elegíveis foram distribuídos aleatoriamente em dois conjuntos: 370 para treinamento (80%) e 93 para teste (20%). Utilizou-se estratificação pela região geográfica intermediária, conforme a classificação do IBGE (2017), a fim de preservar a representatividade regional em ambos os conjuntos. Uma semente aleatória fixa foi definida para assegurar a reprodutibilidade do procedimento. Tanto a padronização das variáveis quanto o ajuste do K-means foram realizados exclusivamente com os dados de treinamento. Posteriormente, os municípios do conjunto de teste foram atribuídos ao centróide mais próximo, sem participação no ajuste do modelo. O treinamento foi executado uma única vez, e o modelo resultante foi persistido para utilização posterior.

O número de agrupamentos foi estabelecido em k = 5 antes do treinamento, como parte do protocolo metodológico. Para subsidiar essa escolha, calculou-se o coeficiente de silhueta (ROUSSEEUW, 1987) no conjunto de treinamento para valores de k entre 3 e 7, conforme apresentado na Figura 9, à esquerda. Os resultados permaneceram próximos entre k = 3 e k = 6: 0,271, 0,252, 0,263 e 0,272, respectivamente. Para k = 7, o coeficiente caiu para 0,226. A diferença de apenas 0,009 entre o resultado de k = 5 e o máximo observado, em k = 6, indica que a métrica não oferece uma vantagem expressiva para a adoção de seis grupos. Dessa forma, optou-se por cinco agrupamentos, priorizando a parcimônia e a interpretabilidade comercial. Essa configuração permite identificar perfis relevantes para o direcionamento de ações sem fragmentar excessivamente o mercado em grupos potencialmente pouco representativos. Os valores relativamente modestos de silhueta também são compatíveis com a natureza dos dados socioeconômicos analisados, nos quais as diferenças entre grupos podem ser graduais, sem fronteiras claramente definidas.

Como o K-means é um método não supervisionado, não há rótulos de referência que permitam avaliar o desempenho por meio de métricas de acurácia. A avaliação no conjunto de teste foi, portanto, baseada em três critérios complementares, apresentados na Tabela 10. O primeiro foi o coeficiente de silhueta, utilizado para comparar a qualidade dos agrupamentos entre treinamento e teste. O segundo foi a distância média dos municípios ao centróide do respectivo grupo, cuja razão entre os valores de teste e treinamento próxima de 1 sugere comportamento semelhante entre os conjuntos e ausência de evidências relevantes de sobreajuste segundo esse indicador. O terceiro critério foi a concordância entre as atribuições do modelo avaliado e as de um modelo de referência ajustado com todos os dados, expressa pela proporção de municípios do conjunto de teste que receberam o mesmo grupo em ambas as configurações. Essa comparação foi complementada pelo índice de Rand ajustado (HUBERT; ARABIE, 1985), que considera a concordância entre agrupamentos e corrige o resultado esperado ao acaso.

Tabela 10: Avaliação do modelo (treino × teste)

Métrica	Treino	Teste	Leitura
Municípios	370	93	Divisão 80/20 estratificada por região intermediária
Coeficiente de silhueta	0,263	0,207	Positiva e na mesma ordem de grandeza nos dois conjuntos
Distância média ao centróide	2,078	2,193	Em desvios-padrão
Razão de distância teste/treino	—	1,06	Próxima de 1: sem sinal de sobreajuste
Concordância com o modelo de referência	—	61,3%	Estabilidade moderada
Índice de Rand ajustado (ARI)	—	0,429	0 = concordância aleatória; 1 = idêntica

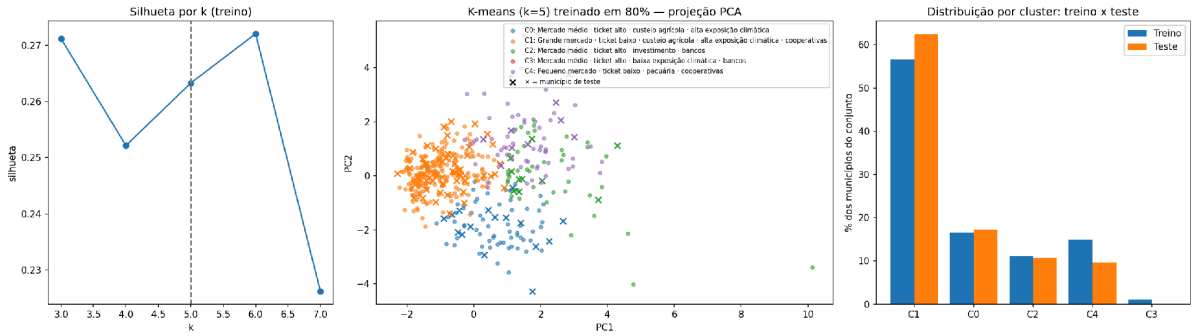
Fonte: resultado do script 03_ml_clusters.py (tabela ml_metricas).

No conjunto de teste, a distância média dos municípios ao centróide de seus respectivos grupos foi 6% superior à observada no treinamento (razão de 1,06), indicando que os municípios não utilizados no ajuste apresentam níveis de aderência aos agrupamentos semelhantes aos do conjunto de treinamento, sem evidências relevantes de sobreajuste segundo esse indicador. O coeficiente de silhueta no teste foi de 0,207, inferior ao valor de 0,263 obtido no treinamento, mas ainda positivo e da mesma ordem de grandeza. Essa diferença deve ser interpretada considerando o tamanho reduzido do conjunto de teste, composto por 93 municípios distribuídos em cinco grupos. A concordância com o modelo de referência foi de 61,3%, com índice de Rand ajustado (ARI) de 0,43, indicando estabilidade moderada das atribuições. Os resultados sugerem consistência nos núcleos dos grupos, embora municípios situados nas fronteiras entre perfis possam ser alocados de maneira distinta conforme a amostra utilizada no ajuste. Assim, os agrupamentos devem ser interpretados como perfis predominantes, e não como categorias rígidas. A distribuição percentual dos municípios entre os cinco grupos também apresentou comportamento semelhante nos conjuntos de treinamento e teste (Figura 9, à direita), sendo a maior diferença observada no cluster C4, que representou 14,9% do treinamento e 9,7% do teste.

Na Figura 10, os cartões apresentam as métricas com três casas decimais, enquanto a tabela utiliza duas casas decimais para a coluna Teste e expressa a concordância em formato fracionário. Dessa forma, o valor 0,61 apresentado na

tabela corresponde aos 61,3% registrados na Tabela 10 e no cartão correspondente, enquanto o valor 93,00 representa a quantidade de municípios do conjunto de teste.

Figura 9: Silhueta por k, projeção dos clusters em componentes principais e distribuição treino × teste



Fonte: resultado do script 03_ml_clusters.py.

A caracterização dos grupos é apresentada na Tabela 11. As denominações foram atribuídas automaticamente, com base na posição relativa das médias de cada grupo em comparação aos demais. Os indicadores utilizados para descrever os perfis (participações, ticket médio, taxa de juros e prejuízo por contrato) correspondem às médias aritméticas dos valores municipais, e não a proporções calculadas sobre os totais agregados de cada grupo. Essa distinção explica, por exemplo, a classificação do cluster C2 como “bancos”, embora o Sicredi represente 42% do valor contratado no grupo. Nesse caso, a participação média das cooperativas de crédito entre os municípios do C2 é de 39%, a menor entre os cinco grupos, o que fundamenta a denominação atribuída pelo modelo.

Tabela 11: Perfil dos clusters de municípios

Cluster	Municípios (treino / teste)	Part. no valor	Perfil de crédito	Concentração geográfica
C1 · Grande mercado · ticket baixo · custeio agrícola · alta exposição climática · cooperativas	267 (209 / 58)	81,0%	Custeio 70%; soja, milho e trigo; cooperativas 60%; ticket de R$ 52,6 mil	Norte e Noroeste (regiões de Passo Fundo e Ijuí: 83% do valor do grupo), além de Canguçu e São Lourenço do Sul

Cluster	Municípios (treino / teste)	Part. no valor	Perfil de crédito	Concentração geográfica
C0 · Mercado médio · ticket alto · custeio agrícola · alta exposição climática	77 (61 / 16)	9,5%	Soja e bovinos; pecuária 33%; maior taxa média (5,17% a.a.); prejuízo declarado de R$ 667 mil por contrato; Banco do Brasil à frente (38% do valor do grupo)	Centro e Missões (Júlio de Castilhos, Cruz Alta, São Luiz Gonzaga, Santiago), com presença também na Campanha e na Fronteira Oeste
C2 · Mercado médio · ticket alto · investimento · bancos	51 (41 / 10)	5,3%	Investimento 61%; uva e tratores; maior volatilidade entre safras	Serra (Flores da Cunha, Bento Gonçalves, Carlos Barbosa, Garibaldi)
C4 · Pequeno mercado · ticket baixo · pecuária · cooperativas	64 (55 / 9)	3,7%	Pecuária 50%; menor ticket (R$ 49,5 mil); cooperativas 60%	Vale do Taquari (Teutônia, Estrela, Arroio do Meio, Putinga)
C3 · Mercado médio · ticket alto · baixa exposição climática · bancos	4 (4 / 0)	0,5%	Grupo residual de municípios atípicos, sem prejuízo declarado	Farroupilha, Sentinela do Sul, Capela de Santana e Palmares do Sul

Fonte: resultado do K-means (k = 5), tabelas ml_perfil_clusters e ml_cluster_municipio, com produtos e instituições calculados no data warehouse. Percentuais de custeio, pecuária e cooperativas, ticket, taxa e prejuízo por contrato são médias simples dos municípios do grupo, a participação no valor e a liderança de instituição referem-se ao valor agregado do grupo.

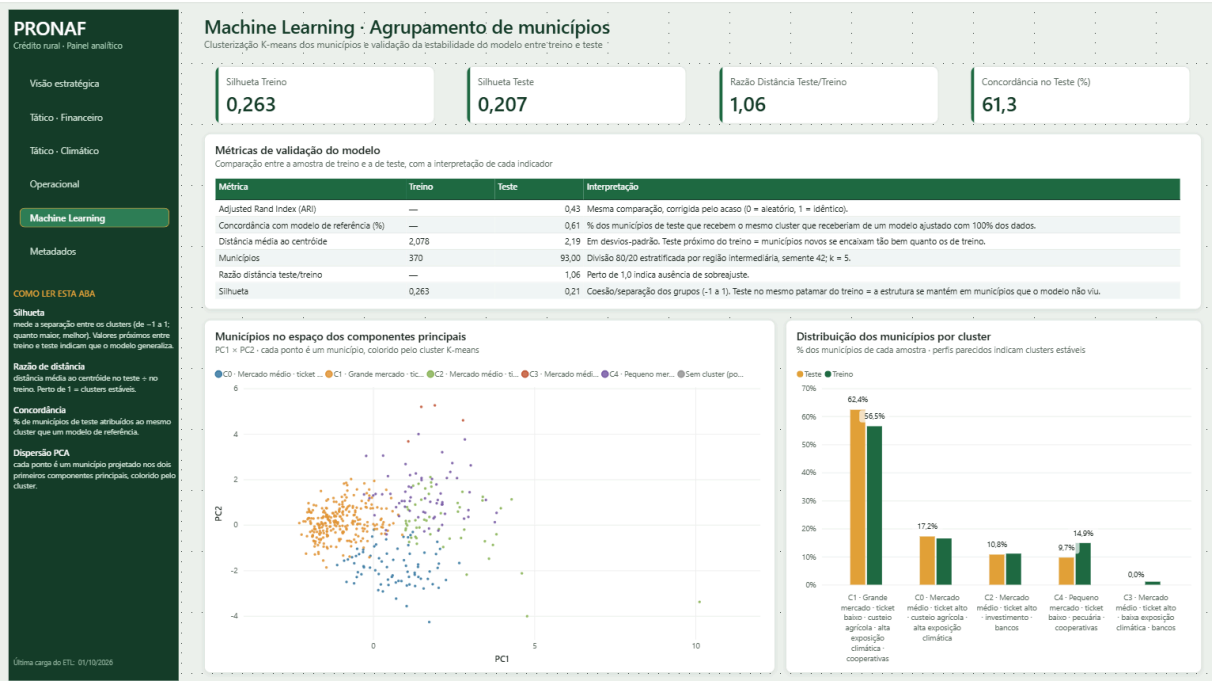
O resultado mais expressivo da segmentação é a predominância do cluster C1, que reúne 267 municípios e concentra 81% do valor contratado. Esse resultado indica que o crédito Pronaf no Rio Grande do Sul se concentra majoritariamente em um perfil caracterizado pela produção de grãos, pela predominância do custeio e pela forte presença de cooperativas de crédito. Nesse contexto, a principal contribuição da segmentação é identificar os quatro nichos que se diferenciam desse perfil predominante, cada qual com características próprias quanto aos produtos financiados, aos canais de crédito e à exposição climática. O cluster C3, por reunir apenas quatro municípios, nenhum deles presente no conjunto de teste, deve ser interpretado como um agrupamento residual, cuja representatividade e capacidade de generalização são limitadas.

Uma validação adicional, de caráter qualitativo, consiste na análise da coerência espacial dos agrupamentos. Embora nenhuma variável geográfica tenha

sido fornecida ao algoritmo, entre os nove atributos utilizados não há latitude, longitude ou indicadores de região e mesorregião, os grupos apresentam correspondência com regiões produtivas conhecidas do Rio Grande do Sul. O cluster C2 está associado à Serra, marcada pela produção de uva e outras frutas, o C4, ao Vale do Taquari, com destaque para a pecuária leiteira, já o C0, às regiões Central e das Missões, estendendo-se à Campanha e à Fronteira Oeste e o C1, ao Norte e Noroeste, caracterizados pela produção de grãos. Essa distribuição, observada no mapa da Figura 4, sugere que os atributos relacionados ao crédito rural e à exposição climática capturam diferenças estruturais associadas à organização produtiva do estado.

No painel, a classificação dos municípios está disponível por meio das cores do mapa da aba Visão Estratégica e de uma coluna específica na tabela municipal. A aba Machine Learning complementa essa visualização com os resultados da avaliação do modelo, apresentados em cartões de indicadores, uma tabela comparativa com a interpretação das métricas, um gráfico de dispersão dos municípios nos dois primeiros componentes principais e um gráfico de colunas que compara a distribuição dos municípios entre os grupos nos conjuntos de treinamento e teste (Figura 10).

Figura 10: Aba Machine Learning



Fonte: painel desenvolvido pelo autor.

5. Registros de Homologação

A homologação teve como objetivo verificar a correspondência entre os valores apresentados no painel e os dados produzidos pelo processo de ETL. Para isso, foram selecionadas três medidas, conferidas manualmente com os arquivos CSV gerados pela carga, com evidências registradas por capturas de tela. Os testes abrangeram três tipos de verificação: contagem de registros, soma de valores e soma condicionada a um filtro dimensional, contemplando assim, as duas tabelas de fato do modelo e duas camadas do processo de dados, sendo staging e data warehouse.

Os valores apresentados no painel foram obtidos da linha de total da tabela Resumo por município, disponível na aba Operacional, que exibe os números sem abreviações. Essa escolha evita ambiguidades decorrentes das unidades de exibição utilizadas nos cartões da aba Visão estratégica, como “1,288 Mi” para contratos e “73,85 Bi” para valores monetários.

O primeiro teste (H1) compara o total da coluna Reconhecimentos, exibido no painel, com a quantidade de linhas do arquivo “fato_evento_climatico.csv”, no qual cada registro corresponde a um reconhecimento federal de desastre. O segundo teste (H2) confronta o total da coluna Qtde Contratos com a quantidade de linhas do arquivo de staging “operacoes_pronaf_rs.csv”, que mantém um registro por operação, e com a soma da coluna “qtde_contratos” do arquivo “fato_contratacao_pronaf.csv”. Essa verificação permite avaliar se a agregação dos dados no grão mensal preservou a quantidade original de operações, sem perdas ou duplicações.

Por fim, o terceiro teste (H3) verifica o total da coluna Valor Contratado após a aplicação do filtro de safra 2023/2024 no painel. O valor obtido é comparado com a soma da coluna “valor_contratado” do arquivo “fato_contratacao_pronaf.csv”, considerando apenas os registros cujo meses estão compreendidos entre julho de 2023 e junho de 2024, identificados pelo intervalo de “ano_mes” entre “202307” e “202406”. Dessa forma, o teste verifica simultaneamente a aplicação do filtro dimensional e a correta implementação da regra de ano-safra.

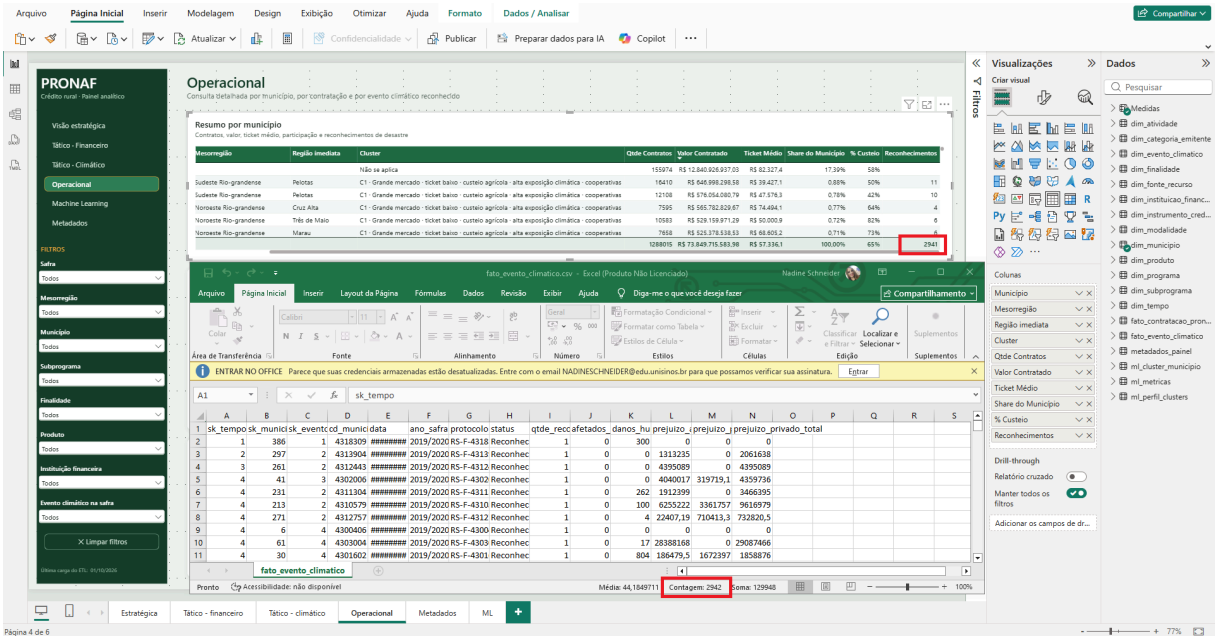
Tabela 12: Testes de homologação (painel × arquivos de dados)

#	Medida no painel	Filtro	Arquivo conferido	Procedimento	Painel	Arquivo
H1	Reconhecimentos (total da tabela Resumo por município)	nenhum	fato_evento_climatico.csv	nº de linhas	2.941	2.941 (2.942 com o cabeçalho do CSV)
H2	Qtde Contratos (total da mesma tabela)	nenhum	operacoes_pronaf_rs.csv (staging) e fato_contratacao_pronaf.csv	nº de linhas e soma de qtde_contratos	1.288.015	1.288.015 (1.288.016 com o cabeçalho do CSV) e 1.288.015
H3	Valor Contratado (total da mesma tabela)	Safra 2023/2024	fato_contratacao_pronaf.csv	soma de valor_contratado com ano_mes entre 202307 e 202406	R$ 15.483.437.068,26	R$ 15.483.437.068,26

Fonte: elaborado pelo autor. Valores do painel lidos na linha de total da tabela Resumo por município (aba Operacional), que os exibe sem unidades de exibição, com duas casas decimais.

Os três testes apresentaram igualdade exata de valores entre o painel e os arquivos de dados. Na Figura 11 é exibido o teste de homologação H1, nota-se que há divergência entre o total da planilha e o painel em uma unidade, isso se deve ao cabeçalho do CSV.

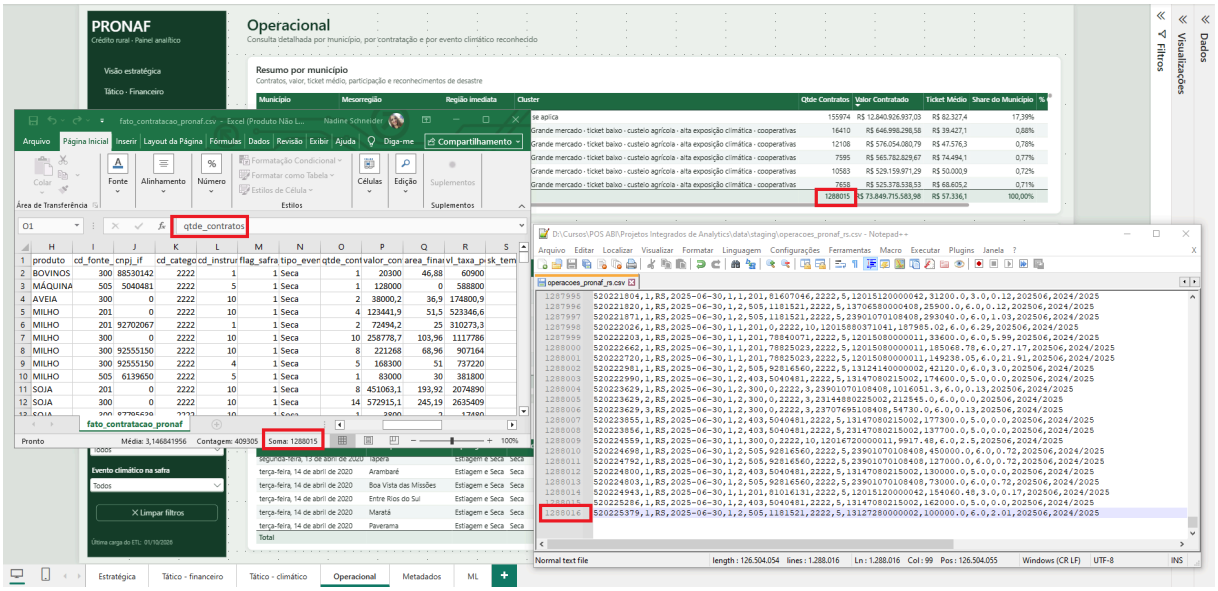
Figura 11: Evidência do teste H1



Fonte: elaborado pelo autor.

Na figura a seguir é exibido o resultado do teste de homologação H2. Assim como no teste anterior, neste também há a divergência em uma unidade da quantidade total de linhas no arquivo CSV, isso se dá também por conta do cabeçalho.

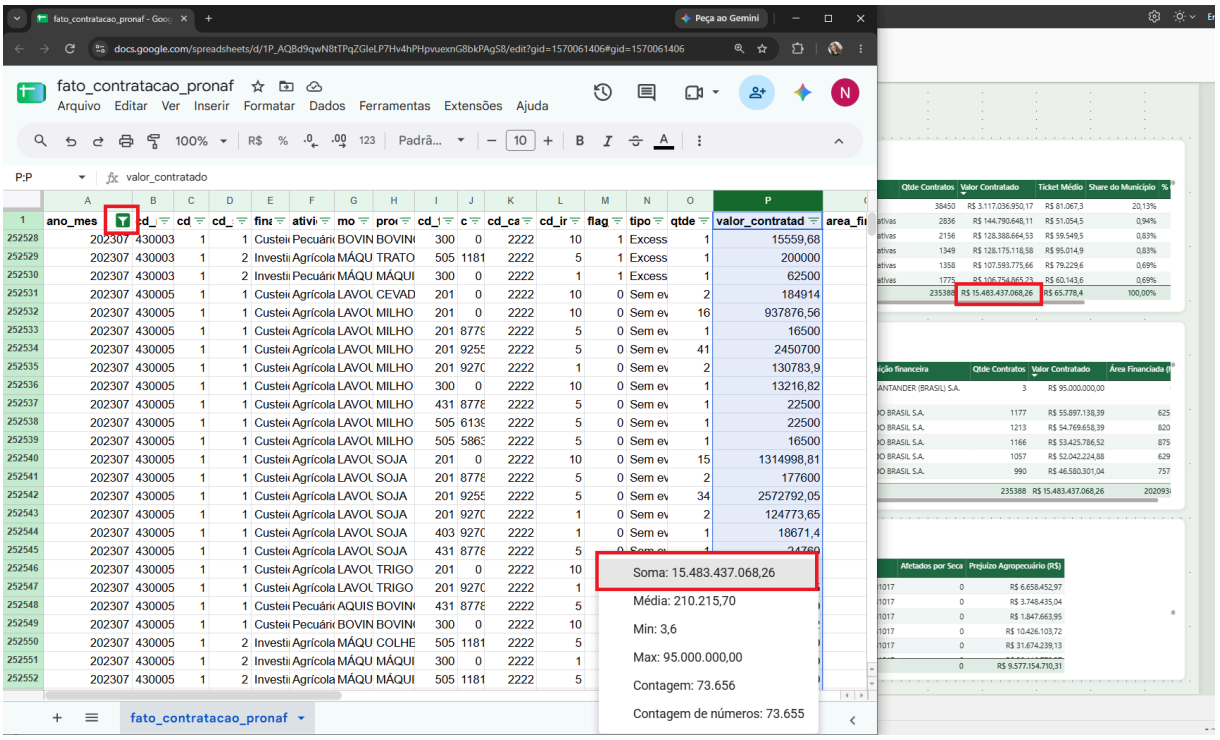
Figura 12: Evidência do teste H2



Fonte: elaborado pelo autor.

Na Figura 13, por sua vez, é exibido o teste de homologação H3. O valor da soma de valor contratado é igual entre o painel e o arquivo bruto fato_contratacao_pronaf.csv. Este arquivo CSV por necessitar a aplicação de um filtro, foi aberto no Google Sheets, diferente dos outros testes onde o arquivo CSV foi aberto em um bloco de notas ou Excel. Mas isso não altera o resultado da homologação.

Figura 13: Evidência do teste H3



Fonte: elaborado pelo autor.

Como verificação complementar de plausibilidade, os totais do data warehouse foram comparados com informações divulgadas publicamente pelas próprias instituições financeiras, conforme documentado na aba Metadados. Para a safra 2023/2024 (SICREDI, 2024), o Sicredi informou ter financiado R$ 6,4 bilhões em operações do Pronaf no Rio Grande do Sul, exatamente o valor registrado no data warehouse. Já para a safra 2022/2023 (RIO GRANDE DO SUL, 2023), o Banrisul divulgou um valor parcial de R$ 1,5 bilhão, frente aos R$ 1,36 bilhão registrados na base. As diferenças, entre aproximadamente 5% e 9%, podem decorrer de critérios distintos de apuração, como o uso do valor liberado nas divulgações institucionais e do valor contratado no SICOR, diferenças nas datas de

corte e limitações na identificação das instituições a partir dos nomes registrados na base. Essa comparação tem caráter indicativo e não substitui os testes formais H1 a H3, pois permite avaliar a compatibilidade da ordem de grandeza dos valores, mas não comprova sua correspondência exata.

6. Conclusões

6.1. Análise crítica dos achados

O primeiro achado evidencia uma divergência em relação à hipótese que orientava informalmente a estratégia comercial da organização. O mercado de crédito do Pronaf no Rio Grande do Sul apresenta baixa concentração geográfica, os dez municípios com maior volume contratado, liderados por Canguçu, São Lourenço do Sul e Ibirubá, representam apenas 8,7% do valor contratado com município identificado. Esses resultados indicam que a cobertura de poucos municípios não seria suficiente para alcançar parcela expressiva do mercado. Sob a perspectiva comercial, a priorização baseada exclusivamente no volume contratado tende a ser limitada, enquanto a segmentação por perfil permite identificar necessidades e oportunidades que não são evidentes apenas pelo tamanho do mercado municipal.

O segundo achado diz respeito à sazonalidade das contratações. Julho e agosto, meses iniciais do Plano Safra, concentram 39% do valor contratado no período analisado, enquanto abril, maio e junho representam, conjuntamente, 18%. Essa distribuição reforça a necessidade de antecipar o planejamento comercial ao início do ciclo, preparando as ações de relacionamento e oferta antes do pico de demanda. Também foi identificada uma elevação das contratações no encerramento das safras mais recentes. A partir de junho de 2024, período posterior às enchentes no estado, e principalmente em maio e junho de 2025, os valores mensais alcançaram R$ 1,3 bilhão, acima dos R$ 0,5 bilhão a R$ 0,9 bilhão observados nas primeiras safras. Embora essa evolução coincida temporalmente com o período posterior às enchentes, os dados disponíveis não permitem atribuí-la diretamente a linhas específicas de crédito emergencial. A investigação desse movimento exige uma análise complementar por subprograma, disponível na aba Operacional do painel.

O terceiro achado responde à questão central do trabalho: a relação entre a contratação de crédito rural e a ocorrência de eventos climáticos. Os resultados mostram que esses eventos estão amplamente presentes no período analisado. Considerando o valor total das operações, inclusive aquelas sem município identificado, 67% foram contratados em municípios e safras com reconhecimento de seca ou excesso hídrico. Essa proporção deve ser interpretada considerando que as operações sem identificação municipal não recebem a classificação climática. Observou-se, ainda, que a participação do custeio no valor contratado atingiu 72% na safra 2021/2022 e 71% na safra 2022/2023, coincidentes com os dois períodos de estiagem mais disseminada, que registraram 406 e 381 municípios com reconhecimento, respectivamente. Nas safras seguintes, essa participação recuou para 62% a 63%, chegando a 62% em 2024/2025, apesar dos 308 municípios com reconhecimento de estiagem.

A comparação histórica, contudo, exige considerar diferenças na composição das operações. Na safra 2019/2020, embora 334 municípios tenham registrado reconhecimento de estiagem, a participação do custeio foi a menor da série, de 59%. Esse resultado é influenciado pela presença da finalidade “comercialização”, que representou aproximadamente 6% do valor contratado e aparece no painel apenas nessa safra. Desconsiderada essa parcela, a participação do custeio se aproxima de 63%, patamar semelhante ao das safras mais recentes. Em conjunto, os resultados sugerem que a demanda por custeio pode apresentar uma relação mais expressiva com a ocorrência de estiagens consecutivas, como as observadas entre 2021 e 2023, do que com eventos isolados. Essa interpretação, entretanto, não estabelece uma relação causal.

A comparação entre o ticket médio das operações em safras afetadas e nas demais também não permite concluir que eventos climáticos estejam associados a contratos de menor valor. A razão observada, de 0,94, é influenciada pela composição dos grupos, onde as operações classificadas como sem evento incluem aquelas sem município identificado, cujo ticket médio, de R$ 82,3 mil, supera a média estadual. Além disso, as safras afetadas estão concentradas no final da série, período em que os valores nominais são mais elevados. As análises, portanto, têm caráter descritivo. Como os reconhecimentos abrangem parcela expressiva do território em diversas safras (chegando a 467 municípios com reconhecimento de excesso hídrico em 2023/2024), não há um grupo de controle adequado que permita

isolar o efeito dos eventos climáticos dentro de uma mesma safra. A comparação longitudinal do território entre safras oferece evidências sobre padrões de comportamento, mas não controla fatores como as condições específicas de cada Plano Safra.

O quarto achado evidencia a concentração por produto financiado e instituição financeira. A soja representa R$ 20,3 bilhões do valor contratado no período, enquanto os três principais produtos (soja, bovinos e milho) concentram 54% do total. Na originação do crédito, as cooperativas respondem conjuntamente por 54% do valor contratado. Considerando o agrupamento de instituições utilizado no painel, o Sicredi concentra 43% das contratações, seguido pelo Banco do Brasil, com 28%, e pelo Cresol, com 11%. Em contraste com a dispersão geográfica, esses resultados revelam concentração relevante por produto e canal financeiro, indicando oportunidades para direcionar parcerias comerciais e estratégias de relacionamento com instituições de maior alcance.

Por fim, o quinto achado refere-se à segmentação dos municípios por meio do algoritmo K-means. O modelo identificou um perfil predominante, representado pelo cluster C1, que reúne 267 municípios e concentra 81% do valor contratado. Esse grupo caracteriza-se pela produção de grãos, pela predominância do custeio e pela forte presença de cooperativas de crédito. Os quatro grupos restantes representam nichos com características próprias quanto aos produtos financiados, aos canais de crédito e à exposição climática. A correspondência entre os agrupamentos e regiões produtivas conhecidas do estado, obtida sem o uso de variáveis geográficas no treinamento, reforça a coerência interpretativa dos perfis. A avaliação no conjunto de teste também indicou comportamento semelhante ao observado no treinamento, sem evidências relevantes de sobreajuste segundo a distância aos centróides. Entretanto, a concordância moderada entre as atribuições demonstra que municípios próximos às fronteiras entre perfis podem mudar de grupo conforme a amostra utilizada. Assim, a segmentação deve ser entendida como instrumento de apoio à priorização comercial, e não como uma classificação rígida dos municípios.

6.2. Proposta de intervenção

Com base nos resultados obtidos, propõem-se cinco ações para orientar as decisões dos sócios e da equipe da organização, com foco na priorização comercial,

no fortalecimento dos canais de distribuição e no desenvolvimento de ofertas alinhadas às características de cada segmento.

1. Estruturar a priorização comercial por cluster: recomenda-se substituir a priorização baseada exclusivamente no volume contratado por uma estratégia orientada aos perfis identificados. O cluster C1, que reúne 267 municípios e concentra 81% do valor contratado, representa o principal mercado em volume. Entretanto, apresenta ticket médio municipal de R$ 52,6 mil e participação média das cooperativas de 60% no valor contratado de cada município. A dispersão territorial e o menor valor médio das operações favorecem um modelo de atendimento de menor custo, apoiado em canais digitais e parcerias com cooperativas, em vez de uma estratégia centrada em visitas individuais.
2. Antecipar o calendário de atuação comercial: considerando que julho e agosto concentram 39% do valor contratado no período anual, recomenda-se intensificar as ações de prospecção e relacionamento entre abril e junho. Essa antecipação busca posicionar a organização antes do pico de contratação, permitindo que os produtores conheçam as soluções disponíveis durante o planejamento de suas atividades e a definição das necessidades de financiamento.
3. Fortalecer as parcerias de originação de crédito: as cooperativas respondem por 54% do valor contratado no período, com participação média de 60% nos municípios dos clusters C1 e C4. Esses resultados justificam a formalização de parcerias com os sistemas cooperativos, ampliando o alcance comercial e facilitando o acesso aos produtores. Complementarmente, recomenda-se priorizar o Banco do Brasil como canal de relacionamento no cluster C0, onde a instituição representa 38% do valor contratado. A estratégia deve considerar as particularidades de cada segmento e a presença das instituições financeiras nos respectivos territórios.
4. Desenvolver uma oferta voltada à resiliência climática para o cluster C0: esse grupo, associado às regiões Central e das Missões, com extensão à Campanha e à Fronteira Oeste, apresenta prejuízo agropecuário médio declarado de R$ 667 mil por contrato e a maior taxa média de juros entre os grupos, de 5,17% ao ano. O prejuízo médio é aproximadamente dez vezes superior ao observado no C1, mas deve ser interpretado como uma

estimativa de ordem de grandeza, pois se baseia em valores autodeclarados e pode ser influenciado por municípios com poucos contratos. Diante dessas características, propõe-se avaliar soluções que integrem seguro rural, tecnologias de irrigação e assistência técnica, com o objetivo de reduzir a exposição a riscos climáticos. A disposição dos produtores a pagar por essas soluções, contudo, deverá ser validada antes da definição da oferta comercial.

5. Desenvolver ofertas específicas para os clusters C2 e C4: a Serra, representada pelo C2, e o Vale do Taquari, associado ao C4, apresentam características que justificam abordagens comerciais diferenciadas. No C2, aproximadamente 61% do valor contratado corresponde a investimentos em uva, máquinas e instalações, além de haver maior volatilidade entre safras. Recomenda-se, portanto, estruturar ofertas de equipamentos e infraestrutura alinhadas ao calendário de investimento dos produtores. No C4, caracterizado pela pecuária leiteira e por tickets médios menores, não há prioridade no momento.

Como medida complementar, recomenda-se acompanhar a participação do custeio no valor contratado como indicador de monitoramento de possíveis situações de estresse hídrico, especialmente quando houver estiagens em safras consecutivas. Esse indicador deve ser interpretado em conjunto com os registros de eventos climáticos e os demais dados disponíveis, como sinal para investigação e planejamento, e não como evidência isolada de impacto climático.

6.3. Lições aprendidas

A experiência evidenciou que a qualidade de uma solução analítica depende, sobretudo, da preparação e da compreensão dos dados, e não apenas da construção do painel. O desenvolvimento do pipeline de dados concentrou a maior parte do esforço, especialmente nas etapas de interpretação das fontes, normalização de chaves, decomposição de códigos hierárquicos e tratamento de valores ausentes. Essas atividades foram determinantes para a confiabilidade dos resultados apresentados.

A definição prévia do grão de análise também se mostrou fundamental. A decisão de agregar os dados antes de sua disponibilização ao painel sustentou o desempenho da solução e evitou o processamento desnecessário de registros

individuais. Alterar essa definição após a implementação das medidas exigiria retrabalho significativo. Por isso, declarar explicitamente o grão e avaliar suas implicações antes de iniciar a codificação constitui uma etapa essencial do planejamento de projetos de dados.

Outro aprendizado importante foi a necessidade de validar as regras de negócio sob a perspectiva analítica, e não apenas técnica. A versão inicial da classificação climática considerava somente o mês de emissão da operação, abordagem tecnicamente consistente, mas insuficiente para representar os efeitos de eventos que se estendem além do período de reconhecimento. A limitação foi identificada durante a interpretação dos resultados, reforçando a importância de confrontar os indicadores com o conhecimento do domínio. Da mesma forma, a análise da relação entre estiagem e participação do custeio demonstrou que hipóteses aparentemente intuitivas precisam ser verificadas ao longo de toda a série histórica, pois os padrões observados nem sempre são uniformes.

Na aplicação de aprendizado de máquina, verificou-se que os critérios estatísticos devem ser considerados em conjunto com os objetivos práticos do projeto. O coeficiente de silhueta contribuiu para avaliar a qualidade dos agrupamentos, mas a escolha do número de clusters também precisou considerar a interpretabilidade comercial. A separação entre treinamento e teste permitiu examinar a capacidade de generalização da segmentação e identificar suas limitações, especialmente a estabilidade moderada dos municípios situados nas fronteiras entre perfis. Também se mostrou essencial manter o treinamento do modelo independente das cargas recorrentes de dados. O retreinamento automático a cada atualização poderia alterar a composição dos grupos sem uma decisão explícita, comprometendo a comparabilidade dos resultados ao longo do tempo.

Por fim, a automação demonstrou ser um requisito para transformar scripts isolados em um processo de dados operacional e confiável. A adoção de mecanismos de atualização incremental, gravação atômica de arquivos, prevenção de execuções simultâneas e registro das cargas em log contribuiu para a rastreabilidade e a segurança da execução. Esses cuidados evidenciam que a sustentabilidade de uma solução analítica depende não apenas da correção dos resultados, mas também da capacidade de executar, monitorar e manter o processo de forma consistente, sem depender de intervenções manuais de quem o desenvolveu.

6.4. Limitações e possibilidades de extensão

A principal limitação do estudo está na cobertura geográfica da fonte de dados. Aproximadamente 12,1% das operações, correspondentes a 17,4% do valor contratado, não possuem identificação municipal no arquivo de complemento público do Banco Central. Essa ausência concentra-se em operações sem vínculo direto com um imóvel rural, onde é integral nas finalidades de comercialização e industrialização e alcança 13,5% das operações de custeio. Para preservar a abrangência dos resultados estaduais, os indicadores agregados consideram a totalidade das operações, enquanto as análises municipais utilizam apenas os registros com localização identificada. A categoria “Não informado” permanece visível no painel, permitindo reconhecer essa diferença de cobertura.

Outras limitações dizem respeito à qualidade e à natureza das fontes utilizadas. Os prejuízos agropecuários registrados no Atlas Digital de Desastres no Brasil são autodeclarados pelos municípios e não passam por auditoria, devendo ser interpretados como estimativas de ordem de grandeza. Além disso, a ausência de séries meteorológicas contínuas impede mensurar diretamente a intensidade dos eventos climáticos. O reconhecimento federal de desastre constitui um registro administrativo, condicionado também à iniciativa do município em solicitá-lo, e não uma medida direta de déficit hídrico. Essas características restringem a precisão da análise climática e reforçam o caráter descritivo das relações identificadas entre eventos ambientais e contratação de crédito.

A modelagem apresenta limitações próprias. Como a clusterização não dispõe de rótulos verdadeiros de referência, sua avaliação se baseia na coesão e na estabilidade dos agrupamentos, e não na proporção de classificações corretas. A concordância de aproximadamente 61% no conjunto de teste indica sensibilidade à amostra, sobretudo para municípios situados nas fronteiras entre perfis. Além disso, o cluster C3, composto por apenas quatro municípios, possui caráter residual e representatividade limitada. Os resultados devem, portanto, ser interpretados como uma segmentação exploratória para apoiar decisões comerciais, e não como uma classificação definitiva dos municípios.

Também existem limitações operacionais e cadastrais. A extração de dados do Atlas depende da estrutura da página de downloads, sujeita a alterações que podem exigir ajustes no processo. As bases do Atlas e do IBGE somente são

atualizadas quando removidas da pasta de dados brutos, o que condiciona a renovação dessas fontes. A identificação das instituições financeiras também depende dos nomes registrados no SICOR. Qualquer inconsistência pode afetar a representação da participação dos sistemas financeiros nos indicadores e nos perfis municipais. Outra restrição refere-se aos indicadores climáticos calculados sobre o total estadual, onde tanto a proporção do valor contratado em safras afetadas quanto a comparação de ticket médio incluem no grupo sem evento as operações sem identificação municipal, conforme discutido na Seção 4.1. Por fim, a data de carga exibida no painel é preenchida manualmente, não sendo obtida diretamente dos registros de execução, o que limita a rastreabilidade da atualização dos dados.

As possibilidades de extensão concentram-se no aprimoramento das fontes, no aprofundamento das análises e na evolução operacional da solução. A incorporação de séries meteorológicas do INMET permitiria substituir a classificação climática binária por indicadores contínuos de precipitação e intensidade dos eventos. A inclusão de dados do Proagro possibilitaria investigar a sinistralidade e a cobertura associadas às operações de crédito rural. Já a integração de informações municipais de produção e produtividade do IBGE permitiria calcular indicadores como o volume de crédito por tonelada produzida, ampliando a análise da relação entre financiamento e atividade agropecuária.

A ampliação da janela temporal para as safras seguintes também constitui uma possibilidade, favorecida pela estrutura de carga incremental já implementada. Com uma série histórica mais extensa e fontes complementares, seria possível avançar da análise descritiva para uma abordagem econométrica baseada em efeitos fixos por município e safra. Esse modelo permitiria controlar características locais invariantes no tempo e fatores comuns a cada safra, contribuindo para estimar com maior rigor a associação entre choques climáticos e contratação de crédito. Ainda assim, a interpretação causal dependeria da disponibilidade de dados adequados e da validade das hipóteses de identificação adotadas.

7. Links

Aqui devem ser disponibilizar os links para os artefatos criados (processos de carga, códigos-fonte, painéis, entre outros) e para o vídeo com a apresentação de 5

minutos e para o repositório contendo os códigos fontes ou os artefatos construídos no projeto.

Tabela 13: Artefatos do projeto

Artefato	Descrição	Link
Repositório de código	Scripts de extração, ETL, orquestração, agendamento e aprendizado de máquina; Painel do Power BI Tabelas de fato e dimensões geradas pelo ETL e resultados do modelo	https://github.com/Nadine-Schneider/projetos-integrados-analytics-ABI
SICOR — Banco Central do Brasil	Fonte primária dos dados de crédito rural	https://www.bcb.gov.br/estabilidadefinanceira/micrrural
Atlas Digital de Desastres no Brasil	Fonte dos reconhecimentos federais de desastre	https://atlasdigital.mdr.gov.br
API de localidades do IBGE	Municípios e regionalização	https://servicodados.ibge.gov.br/api/docs/localidades

Fonte: elaborado pelo autor.

REFERÊNCIAS

BANCO CENTRAL DO BRASIL. **Matriz de Dados do Crédito Rural - SICOR**. Brasília: BCB, 2025. Disponível em: https://www.bcb.gov.br/estabilidadefinanceira/micrrural. Acesso em: junho/2026.

BRASIL. Ministério da Integração e do Desenvolvimento Regional. **Atlas Digital de Desastres no Brasil**. Brasília: MIDR, 2025. Disponível em: https://atlasdigital.mdr.gov.br. Acesso em: junho/2026.

FEW, Stephen. **Information dashboard design: displaying data for at-a-glance monitoring**. 2. ed. Burlingame: Analytics Press, 2013.

HUBERT, Lawrence; ARABIE, Phipps. **Comparing partitions**. Journal of Classification, v. 2, n. 1, p. 193-218, 1985.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Divisão regional do Brasil em regiões geográficas imediatas e regiões geográficas intermediárias**. Rio de Janeiro: IBGE, 2017.

KIMBALL, Ralph; ROSS, Margy. **The data warehouse toolkit: the definitive guide to dimensional modeling**. 3. ed. Indianapolis: Wiley, 2013.

PEDREGOSA, Fabian et al. **Scikit-learn: machine learning in Python**. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.

ROUSSEEUW, Peter J. **Silhouettes: a graphical aid to the interpretation and validation of cluster analysis**. Journal of Computational and Applied Mathematics, v. 20, p. 53-65, 1987.

RIO GRANDE DO SUL. Governo do Estado. **Pelo segundo ano consecutivo, Banrisul supera meta e cresce 76% em crédito agrícola**. Porto Alegre, 23 jun. 2023. Disponível em: https://estado.rs.gov.br/pelo-segundo-ano-consecutivo-banrisul-supera-meta-e-cresce-76-em-credito-agricola. Acesso em: out/2026.

SICREDI. **Sicredi consolida-se em primeiro lugar no RS em número de operações de crédito rural**. [S. l.], 11 set. 2024. Disponível em: https://www.sicredi.com.br/coop/uniaorses/noticias/agro/sicredi-consolida-se-em-primeiro-lugar-no-rs-em-numero-de-operacoes-de-credito-rural/. Acesso em: out/2026.